UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

L'Impossibilità dell'Imparzialità: Uno Studio sui Bias Strutturali negli LLM

RELATORE

Prof. Fabio Palomba

Università degli Studi di Salerno

CANDIDATO

XinYu Xu

Matricola: 0512114829

Anno Accademico 2025-2026

Questa tesi è stata realizzata nel

sesa lab

SOFTWARE ENGINEERING
SALERNO

A tutti i ragazzi disastrati

Venuti su dritti che vivono in case cadenti

Tra le rovine delle loro famiglie

Una laurea ad honorem

A voi che siete i più forti

Abstract

I Large Language Model (LLM) hanno acquisito un ruolo pervasivo, ma la loro adozione è gravata dalla presenza di bias sociali, culturali e cognitivi che rischiano di perpetuare disuguaglianze e influenzare negativamente gli utenti finali. Nonostante esistano numerose strategie tecniche di mitigazione, la letteratura manca di un'analisi critica integrata che ne valuti collettivamente l'efficacia e il reale impatto sul fattore umano. Questa tesi si propone di colmare questa lacuna attraverso un duplice approccio: una revisione sistematica dello stato dell'arte e un'indagine qualitativa sulle esperienze e percezioni degli utenti.

Il lavoro produce tre contributi principali. Primo, propone una **tassonomia originale** dei bias e delle relative strategie di mitigazione, strutturata secondo le fasi della pipeline di sviluppo (pre-processing, in-training, intra-processing, post-processing e prompt engineering). Questa classificazione si distingue per l'inclusione esplicita dei **bias emergenti nell'interazione utente-modello**, un aspetto spesso trascurato. Secondo, attraverso un'analisi critica, dimostra che **nessuna strategia di mitigazione è in grado di garantire un modello "privo di bias"** a causa di limiti intrinseci di costo, efficacia e definizione di equità. Terzo, un questionario qualitativo somministrato a 97 utenti rivela un **paradosso comportamentale**: nonostante una consapevolezza intuitiva dei rischi, gli utenti mostrano una tendenza all'accettazione acritica delle risposte che confermano le loro aspettative, evidenziando un divario tra percezione e pratica.

In conclusione, la tesi sostiene che la ricerca di una soluzione tecnica pura sia illusoria. Propone invece un cambio di paradigma verso un'**ecologia di responsabilità condivisa**, in cui la mitigazione efficace dei bias richiede lo sforzo congiunto di sviluppatori (per modelli più trasparenti), regolatori (per quadri normativi) e utenti (per un consumo critico e informato). I risultati forniscono una mappa concettuale per ricercatori e professionisti e un punto di partenza empirico per studi futuri su campioni più ampi e diversificati.

Indice

Elenco delle Tabelle **iv**

1 Introduzione **1**

1.1 Contesto applicativo 1

1.2 Motivazioni e obiettivi 1

1.3 Risultati ottenuti 2

1.4 Struttura della tesi 3

2 Stato dell'arte **4**

2.1 Bias ed Euristiche 5

2.1.1 Approfondimento dei Bias congnitivi 5

2.1.2 L'impatto dei Bias con i Large Language Model 6

2.2 Large Language Model 7

2.2.1 Bias negli LLM 7

2.2.2 Categorie di bias negli LLM 8

2.3 Bias nelle fasi di sviluppo degli LLM 9

2.3.1 Bias relativi ai Dati 9

2.3.2 Pre-training 13

2.3.3 Fine-Tuning e Allineamento (Alignment) 16

2.3.4 Deployment 22

2.4 Rischi di bias all'utente finale 23
2.4.1 Attenzione al Bias di Autorità Algoritmica!!! 25
2.5 Metodi di Mitigazione dei Bias 30
2.5.1 Mitigazione pre-processing 30
2.5.2 Mitigazione in-training 31
2.5.3 Intra-processing 33
2.5.4 Post-processing 34
2.5.5 Prompt Engineering 35
2.5.6 Strategie di Mitigazione dei Bias: Un Approccio Integrato per l'Utente 36

3 Metodo di ricerca **39**
3.1 Obiettivi e domande di ricerca 39
3.2 Strategia di revisione della letteratura 40
3.3 Indagine qualitativa: questionario 40
3.3.1 Campionamento e raccolta dati 41

4 Risultati **43**
4.1 Tassonomia dei bias e strategie di mitigazione 43
4.2 Analisi dei pericoli per l'utente 43
4.3 Risultati del Questionario: Profilo del Campione e Comportamenti d'Uso 44
4.3.1 Profilo Demografico dei Rispondenti 44
4.3.2 Frequenza e Modalità di Utilizzo degli LLM 45
4.3.3 Percezione dei Bias e Atteggiamenti Critici 45
4.3.4 Aspetti Qualitativi: Risposte Aperte 46

7 Discussione **58**
7.1 Analisi della Tassonomia Descritta 58
7.2 Analisi dei Rischi Associati ai Bias per gli Utenti Finali 60
7.2.1 Strategie di Mitigazione Centrate sull'Utente 60
7.3 Discussione dei Risultati del Questionario 62
7.3.1 Un Profilo di Utente Consapevole ma Ancora Vulnerabile . . 62
7.3.2 Il Paradosso dell'Uso Critico: Evitare vs. Affrontare i Bias . . . 62

7.3.3 Il Riconoscimento dei Bias: Tra Percezione e Esperienza Diretta 63
7.3.4 Dalle Preoccupazioni Qualitative all'Ecologia della Responsabilità 63
7.3.5 Limiti del Campione e Direzioni Future 64

6 Conclusioni **55**
6.1 Limiti e Sviluppi Futuri 56
6.2 Impatto del Lavoro 57

7 Discussione **58**
7.1 Analisi della Tassonomia Descritta 58
7.2 Analisi dei Rischi Associati ai Bias per gli Utenti Finali 60
7.2.1 Strategie di Mitigazione Centrate sull'Utente 60
7.3 Discussione dei Risultati del Questionario 62
7.3.1 Un Profilo di Utente Consapevole ma Ancora Vulnerabile . . 62
7.3.2 Il Paradosso dell'Uso Critico: Evitare vs. Affrontare i Bias . . . 62
7.3.3 Il Riconoscimento dei Bias: Tra Percezione e Esperienza Diretta 63
7.3.4 Dalle Preoccupazioni Qualitative all'Ecologia della Responsabilità 63
7.3.5 Limiti del Campione e Direzioni Future 64

Bibliografia **65**
Domande Questionario . . . . . .

Elenco delle tabelle

2.1 Alcuni bias di Selezione 11
2.2 Bias Sociali 11
2.3 Bias nella fase di Fine-Tuning e Allineamento (SFT/RLHF) 21
2.4 Bias cognitivi nell'interazione utente-LLM 25

7.1 Fasi di mitigazione del bias e relativi limiti principali 59
7.2 Strategie di mitigazione centrate sull'utente 60

7.1 Fasi di mitigazione del bias e relativi limiti principali 59
7.2 Strategie di mitigazione centrate sull'utente 60

3 Caratteristiche demografiche del campione (N=97) . . . . . .
4 Frequenza di utilizzo degli assistenti AI (N=97) . . . . . .
5 Scopi principali di utilizzo degli LLM (scala 1-5) . . . . . .
6 Temi principali nelle considerazioni finali (N=73 risposte) . . . . . .

CAPITOLO 1

Introduzione

1.1 Contesto applicativo

L'introduzione dell'architettura *Transformer* [1], basata sul meccanismo di *self-attention*, e il successivo sviluppo dei primi modelli su larga scala come BERT [2] e GPT [3], hanno reso i Large Language Model (LLM) strumenti di impatto per un pubblico vastissimo. Tuttavia, questo campo non è privo di sfide critiche. Una delle questioni più urgenti affrontate dalla letteratura riguarda la **ricerca di equità** (*fairness*) e la **gestione sistematica dei bias** sociali, culturali e cognitivi che questi modelli ereditano, apprendono e rischiano di amplificare [4, 5, 6, 7].

1.2 Motivazioni e obiettivi

La ricerca condotta in questa tesi nasce da un duplice obiettivo. Il primo è quello di fornire una **definizione strutturata e un'analisi critica** sia dei bias che affliggono gli LLM, sia delle strategie di mitigazione proposte, valutandone l'efficacia e i limiti intrinseci. Il secondo obiettivo, strettamente collegato, è quello di **spostare l'attenzione sui rischi per l'utente finale**, spesso trascurati nel dibattito tecnico. È cruciale

comprendere quali pericoli concreti, derivanti dall'interazione con modelli imperfetti, possano ricadere sull'utente in termini cognitivi, decisionali e sociali.

In sintesi, la tesi si propone di rispondere alle seguenti domande di ricerca:

1. Come possono essere classificati i bias e le strategie di mitigazione negli LLM secondo una logica di sviluppo (pipeline)?
2. Quali sono i principali rischi associati ai bias per gli utenti finali?
3. Quali sono le percezioni e le esperienze dirette degli utenti riguardo ai bias negli LLM?

1.3 Risultati ottenuti

Il lavoro ha prodotto i seguenti risultati principali, che saranno discussi in dettaglio nei capitoli successivi:

- Una **tassonomia originale dei bias**, strutturata lungo le fasi della pipeline di sviluppo degli LLM, che integra e supera classificazioni esistenti includendo esplicitamente i **bias emergenti nell'interazione utente-modello**.
- Una **valutazione critica e sistematica** delle strategie di mitigazione (pre-processing, in-training, intra-processing, post-processing, prompt engineering), che ne evidenzia limiti comuni e l'inevitabile **trade-off** tra efficacia, costo e trasparenza.
- L'identificazione di un **paradosso comportamentale** negli utenti: sebbene intuitivamente evitino di delegare decisioni critiche agli LLM, mostrano una tendenza all'accettazione acritica delle risposte che confermano le loro aspettative.
- L'argomentazione a favore di un cambio di paradigma: dalla ricerca di una soluzione tecnica perfetta a un'**ecologia di responsabilità condivisa**, che coinvolga sviluppatori, regolatori e utenti informati.

1.4 Struttura della tesi

Il resto della tesi è organizzato come segue.

- **Capitolo 2 (Stato dell'Arte)**: Definisce i concetti chiave, il funzionamento degli LLM e presenta la tassonomia dei bias (2.3) e delle strategie di mitigazione (2.5) desunta dalla letteratura.
- **Capitolo 3 (Metodologia)**: Descrive in dettaglio gli obiettivi della ricerca, il disegno dello studio e la metodologia adottata, inclusa la somministrazione del questionario qualitativo.
- **Capitolo 4 (Risultati)**: Presenta i dati raccolti documentandosi con lo stato dell'arte e dallo studio qualitativo condotto.
- **Capitolo 7** (Discussione): Analizza i dati raccolti, integrando i risultati del questionario con l'analisi critica della letteratura per rispondere alle domande di ricerca.
- **Capitolo 6 (Conclusioni)**: Riassume i risultati principali, discute l'impatto del lavoro, ne riconosce i limiti e propone direzioni per la ricerca futura.

CAPITOLO 2

Stato dell'arte

Questo capitolo esplora il fenomeno dei *bias* nell'interazione tra processi cognitivi umani e *Large Language Model* (LLM). Nella prima parte (2.1), viene introdotto il concetto di *euristiche*—scorciatoie mentali che ottimizzano il processo decisionale umano, ma che possono condurre a errori sistematici noti come *bias cognitivi* [8, 9]. Vengono analizzati esperimenti seminali, come quello sull'*ancoraggio*, che dimostrano la pervasività di questi meccanismi.

La seconda parte del capitolo (2.2) si focalizza sugli LLM, descrivendone il funzionamento probabilistico e la dipendenza critica dai dati di addestramento. Si evidenzia come questi modelli, nel replicare pattern linguistici umani, assorbano e possano amplificare i bias presenti nella società [10, 11]. Viene quindi proposta una categorizzazione dei bias negli LLM, distinguendo tra *bias intrinseci* (legati ai dati e all'architettura) ed *estrinseci* (emersi durante l'applicazione) [7].

La terza parte 2.3 fornisce una panoramica dei bias riscontrati nella letteratura, dividendoli per le varie fasi della pipeline dello sviluppo di un LLM: **Data Collection** (2.3.1, **Pre-Training** (2.3.2), **Fine-tuning e Alignment** (2.3.3), **Deployment** (2.3.4) e Bias dannosi all'utente (2.4)

La quarta parte fornisce le varie strategie di mitigazioni di bias, divisi sempre con il riferimento di pipeline di sviluppo.

Infine, il capitolo delinea l'approccio metodologico di questa ricerca: anziché utilizzare una tassonomia tematica dei bias (culturale, di conferma, politico) come proposto da [5], si adotta una prospettiva *longitudinale* che traccia l'origine e la propagazione dei bias attraverso le diverse fasi della pipeline di sviluppo degli LLM. Questa analisi per fasi costituirà il quadro concettuale per le indagini empiriche presentate nei capitoli successivi.

2.1 Bias ed Euristiche

La ricerca in psicologia cognitiva ha ormai ampiamente dimostrato che la nostra mente tende a operare in modo efficiente, privilegiando spesso la conservazione di energie cognitive. Questo meccanismo, per lo più inconscio, si basa sull'utilizzo di *scorciatoie mentali*, note come euristiche [8]. Le euristiche sono strategie semplici che forniscono soluzioni "sufficientemente buone" (*satisficing*) [12], permettendoci di giungere a decisioni accettabili con uno sforzo mentale ottimale.

Un esempio classico di euristica intesa come scorciatoia mentale è l'*availability heuristic* (euristica della disponibilità), descritta per la prima volta da [8]. Questo fenomeno, approfondito nel celebre libro di [9], dimostra come la nostra mente sostituisca spesso una domanda complessa ("Quanto è probabile?") con una più semplice ("Quanto è facile da ricordare?").

Questo stesso principio è stato poi replicato in innumerevoli contesti, dagli affari alla legge, dimostrandone la robustezza [9].

Tuttavia, sebbene questi processi siano essenziali per la velocità del nostro processo decisionale (*decision making*), le stesse scorciatoie possono talvolta condurci a errori di valutazione sistematici e prevedibili. A questi errori si dà il nome di bias cognitivi [9].

2.1.1 Approfondimento dei Bias congnitivi

I bias cognitivi sono, quindi, automatismi mentali dai quali si generano credenze e da cui si traggono decisioni veloci. Si tratta, il più delle volte di errori di giudizio

che impattano, nella quotidianità, non solo su decisioni e comportamenti ma anche sui processi di pensiero.

L'origine, però, del bias cognitivo risale alle ricerche degli psicologi Tversky e Kahneman eseguite negli anni '70, grazie alle quali hanno ricevuto il premio Nobel nel 2002. Lo scopo di queste ricerche era analizzare in quale modo gli esseri umani prendono le loro decisioni in contesti dominati dall'incertezza e con limitate risorse individuali.[13]

Esperimento del bias di ancoraggio

Un esperimento paradigmatico che dimostra la potenza e la pervasività dei bias cognitivi è quello sull'*anchoring* (ancoraggio) condotto da [8]. Nell'esperimento, i partecipanti dovevano stimare la percentuale di nazioni africane nelle Nazioni Unite. Il dato cruciale era che, prima di rispondere, essi dovevano girare una ruota della fortuna che si fermava soltanto su due numeri: 10 o 65.

I risultati mostrarono un effetto drammatico di questo numero ancoraggio, palesemente casuale, sulle stime finali. Il gruppo esposto al numero basso (10) fornì una stima media significativamente più bassa (25%) rispetto al gruppo esposto al numero alto (65%), la cui stima media fu del 45%. Come conclusero [8], questo dimostra che le persone partono da questo valore iniziale e compiono delle regolazioni insufficienti per arrivare alla loro risposta finale, anche quando l'ancora è del tutto arbitraria.

2.1.2 L'impatto dei Bias con i Large Language Model

I bias cognitivi, sistemi di elaborazione mentale che portano a deviazioni sistematiche dal giudizio razionale [9], producono negli esseri umani scelte la cui correttezza è spesso contestuale e fortuita. Tuttavia, il loro impatto più insidioso risiede nella loro capacità di generare e perpetuare informazioni già distorte (informazioni "soggettate a bias"), che a loro volta alimentano un ciclo di pensiero alterato.

Nel contesto dell'Intelligenza Artificiale, specialmente per quanto riguarda i Large Language Models (LLM), avere piena consapevolezza del peso di questi bias è fondamentale [11]. Questi modelli, infatti, vengono addestrati su immensi dataset composti da miliardi di informazioni prodotte dagli esseri umani [10]. Di conseguen-

za, non solo apprendono i pattern linguistici e le conoscenze factuali presenti nei testi, ma assimilano anche i pregiudizi sociali, gli stereotipi culturali e le distorsioni cognitive in essi incorporati [14]. La "logica" statistica di un LLM non può distinguere tra un fatto verificato e un'opinione distorta ripetuta frequentemente online; per il modello, un pattern ricorrente è, per definizione, un pattern da apprendere e replicare. Pertanto, senza un intervento deliberato di mitigazione, un LLM rischia di amplificare e scalare i bias umani esistenti, presentandoli come verità oggettive [15].

2.2 Large Language Model

Un Large Language Model (LLM) è un tipo di modello di intelligenza artificiale addestrato su una quantità enorme di dati testuali (**miliardi o trilioni di parole**[16, 17, 18, 19, 20, 21, 22]) per comprendere, generare e manipolare il linguaggio umano in modo **statistico**. I LLM sono, dal punto di vista architetturale, modelli di generazione probabilistica autoregressivi. Il loro funzionamento si basa sul principio di prevedere l'elemento successivo in una sequenza, un token alla volta. Nel gergo tecnico, infatti, il testo viene processato non in parole intere ma in token, unità più piccole che possono rappresentare una parola, una sottoparola o un singolo carattere [23]. Questa natura intrinsecamente probabilistica è la ragione per cui la stessa richiesta può produrre output leggermente diversi, ed è anche la fonte della loro creatività e fluidità. Tuttavia, è proprio questo meccanismo che li rende vulnerabili all'assimilazione e alla riproduzione dei bias cognitivi presenti nei dati di addestramento [10], poiché i pattern distorti appaiono statisticamente probabili al modello.

L'analisi delle varie fasi di sviluppo di un LLM, verrà descritto meglio nelle sezioni successive (2.3).

2.2.1 Bias negli LLM

Come anticipato, gli LLM sono estremamente dipendenti dai dati su cui vengono addestrati, in quanto il loro funzionamento si basa su principi probabilistici. È più corretto affermare che un LLM non "ragiona" in senso umano, ma effettua una predizione sulla probabilità del token successivo in una sequenza. Quando que-

sta predizione porta a un risultato indesiderato o dannoso, spesso è a causa della presenza di bias nei dati di training o nell'algoritmo stesso [24].

La presenza di bias negli LLM è un problema profondo e sistemico, ampiamente considerato *non risolvibile* nel breve e medio termine [10]. Nonostante ciò, è fondamentale analizzare e definire le origini di questi bias per comprendere le direzioni della ricerca attuale e gli sforzi di mitigazione in corso. Il problema è intrinseco alla natura dei dati di addestramento: gli LLM si specchiano nella società da cui quei dati provengono, riflettendone e, a volte, amplificandone stereotipi, disuguaglianze e discriminazioni preesistenti [11].

2.2.2 Categorie di bias negli LLM

Come descritto da [7], gli LLM manifestano *bias* riconducibili a due categorie principali. Il **bias intrinseco** origina dai dati e dalle scelte di progettazione del modello, portando gli LLMs a ereditare e potenzialmente rafforzare stereotipi presenti nei corpora di addestramento, come associazioni di genere nelle professioni o rappresentazioni inadeguate di gruppi demografici [11]. Questo costituisce un rischio significativo in contesti decisionali sensibili [10].

Il **bias estrinseco**, invece, emerge durante l'applicazione pratica degli LLM in compiti specifici (ad esempio, analisi del sentimento o moderazione di contenuti), manifestandosi in modo spesso sottile attraverso gli output generati dal modello. La distinzione tra queste due fonti di tendenza sistematica è fondamentale per lo sviluppo di strategie di mitigazione efficaci[7].

Mentre [5] propone una tassonomia più concisa dei *bias* negli LLM—categorizzandoli in **bias culturale**, **bias di conferma** e **bias politico**—, il presente lavoro adotta un approccio metodologico analogo, ma con una schematizzazione incentrata sulle diverse fasi della *pipeline* di sviluppo dei modelli linguistici. In particolare, la ricerca analizza sistematicamente come i bias possano originarsi e propagarsi in ciascuno stadio del processo, dall'acquisizione dei dati all'addestramento fino al deployment.

2.3 Bias nelle fasi di sviluppo degli LLM

Il presente capitolo analizza i principali bias che insorgono nelle diverse fasi della pipeline di sviluppo degli LLM. Per ogni fase, si descrive il processo coinvolto e si identificano i bias caratteristici, giustificandone l'origine con evidenze empiriche tratte dalla letteratura.

2.3.1 Bias relativi ai Dati

ChatGPT e altri sistemi basati su *Large Language Model* (LLM) vengono addestrati attraverso un processo di **apprendimento non supervisionato**, in cui il modello assimila schemi linguistici e strutture semantiche da enormi quantità di dati testuali non etichettati [25, 26]. Nella maggior parte dei casi, queste informazioni provengono da testi pubblicamente disponibili in rete - come siti web, articoli, libri e altre fonti digitali [2, 27, 21, 17].

Sebbene i dettagli del dataset di addestramento di GPT-4 non siano pubblici [28, 29], è plausibile che le sue fonti siano simili a quelle utilizzate per GPT-3. Quest'ultimo, infatti, si basava sul dataset **WebText** [3, 30, 16], un'ampia collezione di pagine web selezionate in base alla loro qualità linguistica.

L'enorme volume di dati grezzi viene sottoposto a complessi processi di filtraggio e **pre-elaborazione**. Pipeline automatizzate, che includono modelli per la classificazione della qualità e filtri per la tossicità, mirano a rimuovere contenuti duplicati, rumorosi o inappropriati [31]. Tuttavia, data la scala dell'addestramento (nell'ordine di terabyte o petabyte), è impossibile garantire una pulizia perfetta. Di conseguenza, contenuti distorti, stereotipati o discriminatori possono sfuggire ai controlli, essere appresi dal modello e riprodotti nelle sue risposte, generando un effetto di **propagazione e amplificazione dei bias**.

Per questo motivo, la fase di **pre-training** - e in particolare le operazioni di **Data Collection** (raccolta dati) e **Data Processing** (elaborazione dei dati) - risulta cruciale per limitare l'insorgenza di bias nei modelli linguistici. Questa fase può essere considerata la più impattante per l'addestramento di un LLM. Il principio "*garbage in, garbage out*" sottolinea infatti come la qualità dei dati di addestramento o di fine-tuning condizioni direttamente le prestazioni del modello risultante [32]. Tale

principio è supportato dalle ricerche di [33] e dalle evidenze sperimentali di [34], che dimostrano come un LLM tenda a performare meglio quando addestrato su pochi dati di alta qualità piuttosto che su grandi volumi di dati scadenti.

Data Collection

La raccolta dei dati costituisce la base dello sviluppo di un LLM: in questa fase vengono assemblati i corpus testuali su cui il modello viene pre-addestrato (*pre-training*). L'obiettivo è creare un dataset ampio e diversificato, che altrimenti potrebbe portare a diversi tipi di bias pericolosi e/o a bias a cascata nelle fasi successive dello sviluppo. Tuttavia, questa stessa ampiezza introduce rischi significativi di distorsione. In particolare descriviamo due tassonomie per identificare i bias in questa fase [6]: **bias di selezione** e **bias culturali**

Bias di Selezione

Il **bias di selezione** si riferisce a un errore sistematico che si verifica quando il campione utilizzato in uno studio, in una ricerca o in un dato processo di raccolta dati, non rappresenta correttamente la popolazione di interesse. Questo pregiudizio può influenzare i risultati e le conclusioni, rendendoli non affidabili o non generalizzabili alla popolazione più ampia.

Nonostante gli LLM vengano allenati su un massiccio contenuto disponibile su internet [3, 30, 16], essi rimangono comunque un sottoinsieme della totalità del contenuto. Anche se potessimo allenare il modello sulla totalità dei contenuti presenti su internet, risulterebbe comunque in un modello soggetto a bias [6]. Dunque, la selezione dei dati da utilizzare per l'allenamento è cruciale e inevitabile. Anche le aziende leader, con un budget molto generoso, devono spendere una porzione considerevole di esso per effettuare una selezione di contenuti di qualità e da fonti credibili (es. Wikipedia), mentre si scarta contenuto di scarsa qualità [16]. Se i dati selezionati contengono bias, allora questi bias possono potenzialmente essere assorbiti e riflettersi in comportamenti errati [5].

Tabella 2.1: Alcuni bias di Selezione

Bias	Descrizione	Riferimenti
Campionamento	Si verifica quando i dati non vengono raccolti da un campione rappresentativo, spesso a causa di scelte di convenienza o di criteri di selezione non casuali	[6]
Temporale	Può manifestarsi quando i dati raccolti o le osservazioni sono influenzati da un intervallo temporale particolare, dalla sequenza temporale degli eventi o da cambiamenti nel tempo che alterano la rappresentatività o la validità dei risultati.	[6, 5]

Bias Culturali

I **bias culturali** si verificano quando il modello impara e perpetua bias culturali di vari tipi. Questo può portare a produrre output che rafforza i pregiudizi culturali, come per esempio giudizi di *gender* e *razziali*, portando gravi conseguenze concrete. Un esempio concreto sono i *Hiring AI-driven tool* che potenzialmente si comportano in modo differente in base al gruppo di appartenenza raziale, di gender e di età, rischiando di perpetuare disuguaglianze e squilibri lavorativi.

Tabella 2.2: Bias Sociali

Bias	Descrizione	Riferimenti
Culturale	Tendenza a giudicare gli altri basandosi sugli standard della propria cultura, considerandoli superiori o più corretti.	[35, 36, 37, 38]
Di Genere	Pregiudizi e stereotipi che influenzano percezioni e comportamenti in base al sesso o al genere.	[39, 40, 41, 42]

Bias	Descrizione	Riferimenti
Politico	Tendenza a interpretare le informazioni in base alla propria ideologia, accettando solo ciò che la conferma e rifiutando ciò che la contraddice.	[43, 44, 45, 46]
Età	Discriminazioni o tendenza a credere comportamenti associati a diversi gruppi divise per età	[6]
Orientamento Sessuale	Discriminazione basata sull'orientamento sessuale che porta a una immaginazione offensiva del soggetto	[6]
Nazionalità	La nazionalità viene usata per definire un soggetto solo in base alla personalità definendo comportamenti e pensieri imprescindibili	–
Etnia e Razza	I pregiudizi basati sulla razza e sull'etnia riguardano le percezioni che le persone hanno verso diversi gruppi, e purtroppo tendono a manifestarsi in comportamenti discriminatori, atteggiamenti negativi e reazioni sfavorevoli.	[6]
Socio-economico	Il pregiudizio socioeconomico colpisce tipicamente le persone o i gruppi svantaggiati, come i poveri. Si tratta di una forma di pregiudizio sottile, difficile da identificare quando nascosto all'interno di un discorso o di un testo.	[6]

2.3.2 Pre-training

Il *pre-training* rappresenta la fase fondamentale nello sviluppo dei Large Language Models (LLM), durante la quale il modello apprende pattern statistici, strutture linguistiche e rappresentazioni semantiche a partire da enormi quantità di testo non supervisionato [47]. Questo processo permette al modello di sviluppare conoscenze generali sul linguaggio prima di essere adattato a compiti specifici tramite tecniche come il *fine-tuning* o l'*instruction tuning* [4]. Il concetto di pre-training è stato introdotto in forma moderna con l'architettura *Transformer* [1], che ha permesso di superare i limiti dei modelli ricorrenti e di sfruttare meccanismi di attenzione in grado di catturare dipendenze a lungo raggio. Successivamente, lavori come BERT [2] e GPT [3, 30] hanno mostrato come l'apprendimento auto-supervisionato su grandi corpora text-only permetta ai modelli di esibire capacità emergenti, migliorando significativamente le prestazioni su una vasta gamma di attività linguistiche [3].

Durante il pre-training, il modello apprende obiettivi come la predizione del token successivo (causal language modeling) o la ricostruzione di token mascherati (masked language modeling) [4]. Tali obiettivi consentono al modello di acquisire rappresentazioni distribuite del significato linguistico, un aspetto evidenziato anche nelle analisi sulle proprietà geometriche degli embedding [48, 49].

Il pre-training, tuttavia, non è esente da sfide. Poiché il modello apprende dalle statistiche dei dati testuali, esso può anche catturare bias e distorsioni presenti nei corpora [10]. Questo implica che la fase di pre-training non è solo un passaggio tecnico, ma un momento critico in cui si determina la natura delle rappresentazioni che il modello userà in tutte le fasi successive [4].

Il pre-training costituisce la spina dorsale degli LLM: consente al modello di acquisire conoscenza generale, abilità linguistiche robuste e capacità emergenti che rendono possibili le prestazioni osservate nei modelli contemporanei [4].

Architettura Transformer e Meccanismi di Self-Attention

L'architettura Transformer, introdotta nel lavoro rivoluzionario di [1], rappresenta la base fondamentale per i moderni modelli linguistici di grandi dimensioni utilizzati nella fase di pre-training. La sua adozione ha permesso un salto qualitativo nelle

prestazioni dei modelli, pur introducendo nuove sfide relative alla propagazione dei bias.

Meccanismo di Self-Attention

Il cuore dell'architettura Transformer è il meccanismo di *self-attention*, che permette al modello di processare l'intera sequenza di input simultaneamente, a differenza delle architetture ricorrenti che elaborano gli elementi in modo sequenziale. Come formalizzato da [1], il meccanismo di scaled dot-product attention è definito come:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.3.1}$$

dove Q (Query), K (Key) e V (Value) sono matrici derivate dall'input attraverso trasformazioni lineari, e d_k è la dimensione dei vettori key. La normalizzazione attraverso la radice quadrata di d_k ha lo scopo di stabilizzare i gradienti durante l'addestramento.

La *multi-head attention* estende questo concetto permettendo al modello di partecipare simultaneamente a informazioni da diversi sottospazi di rappresentazione:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)W^O \tag{2.3.2}$$

dove ciascuna testa di attention head_i calcola l'attention in un sottospazio proiettivo diverso.

Amplificazione dei Bias nei Transformer

Sebbene l'architettura Transformer abbia rappresentato un progresso tecnologico significativo [1], essa non soltanto non risolve il problema dei bias nei modelli linguistici, ma può addirittura amplificarli [10]. Questo fenomeno è riconducibile a diverse caratteristiche intrinseche dell'architettura:

Apprendimento di Pattern Statistici: I Transformer apprendono esclusivamente dalle correlazioni statistiche presenti nei dati di training. Come evidenziato da [50], quando i dataset di pre-training contengono rappresentazioni sbilanciate di gruppi sociali o stereotipi culturali, il meccanismo di self-attention impara queste associazioni come fatti statistici validi.

Natura Amplificativa del Meccanismo di Attention: Il calcolo dei pesi di attention agisce come un amplificatore statistico. Associazioni frequenti nei dati di training ricevono pesi più elevati, rinforzando e perpetuando i pattern esistenti [51]. Ad esempio, se nel corpus di pre-training la parola "infermiere" appare statisticamente associata a riferimenti femminili, il modello apprenderà questa correlazione come una regola linguistica.

Scalabilità e Amplificazione dei Bias: La stessa scalabilità che rende i Transformer efficaci per il pre-training su larga scala contribuisce all'amplificazione dei bias. [52] osservano che modelli più grandi e complessi sono in grado di apprendere pattern biasati più sottili e sofisticati, rendendo il problema più pervasivo e difficile da individuare.

Problemi Specifici nei Dataset di Pre-Training

I bias nei Transformer originano principalmente dalla qualità e composizione dei dataset di pre-training. I bias presenti nella fase di data collection vengono successivamente amplificati dal modello, come illustrato nelle Tabelle 2.1 e 2.2.

Implicazioni per il Pre-Training

La comprensione di queste dinamiche è cruciale per lo sviluppo di strategie di pre-training più etiche. Come sottolineato da [53], l'efficienza e scalabilità dei Transformer devono essere bilanciate con considerazioni sulla fairness e rappresentatività dei dati di training.

La ricerca contemporanea sta esplorando diverse strategie per mitigare questi problemi, tra cui l'implementazione di tecniche di *debiasing* durante la fase di pre-training [15] e lo sviluppo di dataset più bilanciati e rappresentativi [54]. Tuttavia, la natura intrinseca del meccanismo di *self-attention* come amplificatore statistico continua a rappresentare una sfida aperta per la comunità di ricerca. Recenti contributi allo stato dell'arte [5, 24] hanno sollevato questioni fondamentali sull'effettiva possibilità di risolvere completamente il problema dei bias. In particolare, [24] invita a una profonda riconsiderazione di ciò che significhi prevenire i danni correlati ai bias,

suggerendo che l'approccio attuale potrebbe richiedere una revisione concettuale piuttosto che ulteriori tentativi di mitigazione tecnica.

2.3.3 Fine-Tuning e Allineamento (Alignment)

Dopo la fase di *pre-training*, il modello base possiede una vasta conoscenza linguistica generale ma non è necessariamente in grado di seguire istruzioni, rispondere in modo utile o allinearsi ai valori umani. Il **fine-tuning** e l'**allineamento (alignment)** sono fasi cruciali successive al pre-training, il cui obiettivo è specializzare il modello e modellarne il comportamento per renderlo più sicuro, affidabile e conforme agli obiettivi desiderati.

Obiettivi del Fine-Tuning

Il fine-tuning rappresenta una fase di addestramento specializzato che mira ad adattare il modello pre-addestrato a compiti, domini o comportamenti specifici. I suoi obiettivi principali possono essere categorizzati come segue:

Adattamento a Compiti Specifici

- **Specializzazione Funzionale**: Trasformare il modello generico in uno strumento capace di svolgere compiti precisi come classificazione di testo, analisi del sentiment, traduzione automatica, o estrazione di informazioni [2].
- **Miglioramento delle Prestazioni**: Ottenere accuracy, precisione e recall superiori rispetto al modello base su domini ristretti, sfruttando la conoscenza generale acquisita durante il pre-training e adattandola al contesto specifico.
- **Apprendimento di Formati Strutturati**: Insegnare al modello a produrre output in formati specifici richiesti dall'applicazione (es. JSON, XML, risposte in stile chatbot).

Adattamento a Domini Specialistici

- **Acquisizione di Terminologia Settoriale**: Addestrare il modello sul linguaggio tecnico e sui concetti propri di domini specialistici come medicina, legge, finanza o ingegneria [55].
- **Comprensione del Contesto Dominio-Specifico**: Permettere al modello di comprendere le relazioni, le convenzioni e il contesto implicito propri di un settore specializzato.
- **Riduzione di Allucinazioni in Contesti Critici**: Minimizzare la generazione di informazioni inaccurate in domini dove la precisione fattuale è essenziale.

Miglioramento del Comportamento Conversazionale

- **Instruction Following**: Insegnare al modello a comprendere e seguire accuratamente le istruzioni fornite dall'utente, abilità fondamentale per assistenti virtuali e sistemi di dialogo [56].
- **Coerenza Contestuale**: Migliorare la capacità del modello di mantenere coerenza all'interno di una conversazione estesa, ricordando il contesto e riferimenti precedenti.
- **Adattamento Stilistico**: Modellare lo stile delle risposte per adattarlo a diversi contesti comunicativi (formale, informale, tecnico, divulgativo).

Allineamento (Alignment)

L'**allineamento** è il processo di modellare il comportamento del modello per farlo agire in modo allineato con le intenzioni e i valori umani. Questo include la capacità di essere utile, onesto e innocuo. Data la natura generativa e potenzialmente influente degli LLM, l'allineamento è una delle sfide più critiche e discusse nello sviluppo dell'IA [57, 58].

Dunque gli obiettivi dell'allineamento sono:

- **Creazione di una Baseline Comportamentale**: Stabilire un comportamento di base coerente su cui applicare successivamente tecniche di allineamento più raffinate come l'RLHF.
- **Dimostrazione di Comportamenti Desiderati**: Fornire al modello esempi concreti di risposte high-quality che incarnano i comportamenti target.
- **Riduzione della Tossicità Iniziale**: Filtrare e correggere comportamenti indesiderati emersi durante il pre-training prima di procedere con fasi di ottimizzazione più complesse.

Apprendimento per Rinforzo con Feedback Umano (RLHF)

L'**Apprendimento per Rinforzo con Feedback Umano** (Reinforcement Learning from Human Feedback, RLHF) è una metodologia avanzata di *alignment* che utilizza segnali di preferenza umana per ottimizzare un modello pre-addestrato, rendendo i suoi output più allineati a concetti soggettivi come utilità, innocuità e appropriatezza. Resa celebre da modelli come InstructGPT (precursore di ChatGPT) e GPT-4 [47, 59], l'RLHF affronta il problema fondamentale che obiettivi complessi come "essere utile" non possono essere facilmente specificati con una semplice funzione di loss.

La metodologia si articola tipicamente in tre fasi sequenziali [47] :

1. **Raccolta del feedback umano:** un modello pre-addestrato genera varie risposte a una serie di prompt. Annotatori umani valutano e ordinano queste risposte in base alla qualità, preferenza e allineamento ai valori desiderati.
2. **Addestramento del modello di ricompensa:** utilizzando i dati di preferenze umane raccolti, si allena un modello separato, chiamato *reward model*, che stima un punteggio numerico rappresentativo della qualità di una risposta rispetto a un prompt.
3. **Ottimizzazione tramite RL:** il modello linguistico viene quindi ulteriormente addestrato utilizzando tecniche di apprendimento per rinforzo, guidato dal modello di ricompensa, per generare risposte che massimizzano la ricompensa prevista e quindi rispecchiano sempre più le preferenze umane.

Bias nel Fine-Tuning e nell'Allineamento

Sebbene il fine-tuning e l'RLHF siano progettati per migliorare il comportamento del modello, possono introdurre o amplificare nuovi bias [60].

Bias nel Dataset di Fine-Tuning

- **Bias di Rappresentazione**: Se il dataset di fine-tuning non è rappresentativo della diversità di utenti, culture o scenari d'uso, il modello imparerà a performare bene solo per i gruppi o i contesti sovrarappresentati [61].
- **Bias degli Annotatori**: I giudizi umani utilizzati nell'SFT e per addestrare il modello di ricompensa sono essi stessi soggetti a bias cognitivi e culturali degli annotatori. Questo può portare il modello a internalizzare e replicare queste prospettive parziali, scambiandole per "preferenze umane universali" [59, 62].

Bias Introdotti dall'RLHF

- **Over-Optimizzazione e "Sycophancy"**: Nel tentativo di massimizzare la ricompensa, il modello può sviluppare un comportamento "sicofante", ovvero tendere a dire ciò che crede l'utente voglia sentire, piuttosto che fornire informazioni accurate. Questo può portare a un'acquiescenza eccessiva o alla riproduzione di pregiudizi impliciti dell'utente [63].
- **Appiattimento delle Prospettive (Homogenization)**: L'RLHF, ottimizzando per un unico modello di ricompensa, rischia di appiattire le risposte del modello verso un'unica "voce" mediamente accettabile, sopprimendo legittime minoranze di opinione o prospettive culturali alternative [60]. Il modello impara a evitare contenuti controversi, a volte a scapito di fornire informazioni complete.
- **Bias di Sicurezza (Safety Bias)**: Politiche eccessivamente conservative per evitare contenuti dannosi possono portare a un *errore del falso positivo*, dove il modello si rifiuta di rispondere a prompt innocui o diventa eccessivamente cauti su determinati argomenti, limitando la sua utilità [64].

- **Allineamento politico**: I modelli allineati tramite RLHF possono produrre risposte predefinite e distorte su questioni controverse (es. immigrazione, diritti sociali), riflettendo le inclinazioni ideologiche degli annotatori umani [38].

In conclusione, il fine-tuning e l'allineamento sono strumenti potenti per rendere gli LLM utili e sicuri, ma il loro utilizzo introduce nuovi meccanismi attraverso i quali i bias possono essere introdotti o amplificati. Una comprensione approfondita di questi processi è essenziale per sviluppare sistemi di IA più equi e robusti. Ma in questa fase dove i bias umani sono più forti, quando l'allineamento viene effettuato in base a ciò che si intende come giusto o sbagliato, come analizzato nel capitolo successivo, l'allineamento è estremamente potente se si vuole indirizzare il modello come strumento di pensiero.

Tabella 2.3: Bias nella fase di Fine-Tuning e Allineamento (SFT/RLHF)

Fase	Bias e Descrizione	Riferimenti
Dataset di Fine-Tuning (SFT)		
Bias di Rappresentazione	Dataset non rappresentativi della diversità di utenti, culture o scenari d'uso portano il modello a performare bene solo per gruppi o contesti sovrarappresentati, marginalizzando gli altri.	[61]
Bias degli Annotatori	I giudizi umani nell'SFT riflettono bias cognitivi e culturali degli annotatori. Il modello internalizza queste prospettive parziali, scambiandole per "preferenze umane universali".	[59, 62]
Allineamento via RLHF		
Sycophancy (Sicofanzia)	Il modello sviluppa comportamento compiacente, dicendo ciò che crede l'utente voglia sentire piuttosto che informazioni accurate, riproducendo pregiudizi impliciti dell'utente.	[63]
Homogenization (Appiattimento)	Ottimizzazione per un unico modello di ricompensa appiattisce le risposte verso una "voce" mediamente accettabile, sopprimendo prospettive di minoranza o alternative culturali.	[60]
Safety Bias	Politiche eccessivamente conservative causano falsi positivi: il modello si rifiuta di rispondere a prompt innocui o diventa eccessivamente cauto, limitandone l'utilità.	[64]

2.3.4 Deployment

La fase di deployment rappresenta il momento in cui un Large Language Model (LLM), dopo essere stato addestrato e ottimizzato, viene effettivamente distribuito e utilizzato in applicazioni reali. Durante questa fase, il modello interagisce con utenti finali o sistemi esterni al contesto controllato dell'addestramento e deve rispondere a input variabili e imprevedibili. È una fase critica poiché il comportamento del modello deve essere monitorato per garantire affidabilità, sicurezza e rispetto di criteri etici e normativi.

Bias nella fase di Deployment e nell'Interazione Dinamica

È in questa fase che i *bias estrinseci* diventano pienamente manifesti, poiché emergono dall'interazione dinamica e spesso imprevedibile tra il modello e i suoi utenti [**?**]. A differenza dei bias intrinseci (legati ai dati) o di quelli introdotti durante l'allineamento (RLHF), i bias di deployment sono spesso *reattivi* e *situati* [7], dipendendo fortemente dal contesto d'uso, dallo scopo dell'utente e dalla specifica iterazione dialettica.

L'interazione utente-modello può essere concettualizzata come un ciclo di feedback in cui l'output del modello influenza il successivo input dell'utente, potenzialmente creando loop di rinforzo o degradazione. In questa dinamica, diversi bias critici possono emergere:

- **Sensibilità al Prompt (Prompt Sensitivity) e Bias di Conferma (Confirmation Bias)**: Gli LLM mostrano un'elevata sensibilità alla formulazione del prompt. Un utente, consciamente o inconsciamente, può *ingegnerizzare* il proprio prompt per ottenere una risposta che confermi le proprie convinzioni preesistenti. Il modello, ottimizzato per soddisfare l'utente, può quindi cadere in un *bias di conferma algoritmico*, fornendo risposte che rinforzano le idee dell'utente piuttosto che offrire una prospettiva equilibrata o correggere misinformazioni [63].

- **Bias di Utilizzo (Usage Bias) e Feedback Loop**: Il comportamento del modello in produzione non è statico; è plasmato dagli utenti che lo interrogano. Se

un certo gruppo demografico o una certa comunità utilizza il modello più intensamente o per scopi specifici, il modello può *imparare* da questo utilizzo differenziale (attraverso meccanismi di apprendimento online o logging). Ciò rischia di creare un *circolo vizioso* (feedback loop) in cui il modello diventa sempre più performante e calibrato per gli utenti più attivi, marginalizzando ulteriormente gli utenti già sottorappresentati [65].

- **Bias Contestuale e della Persona (Persona Bias)**: Durante le interazioni estese, gli utenti possono chiedere esplicitamente o implicitamente al modello di assumere un'identità o un ruolo specifico (es., "agisci come un avvocato conservatore", "rispondi come se fossi un attivista climatico"). Il modello, nel conformarsi a questa "persona", può adottare e amplificare gli stereotipi, le inclinazioni politiche o i pregiudizi culturali associati a quel ruolo, generando output distorti e potenzialmente dannosi [56].

- **Bias di Adattamento Dinamico (Dynamic Adaptation Bias)**: Alcuni sistemi in produzione sono progettati per adattarsi nel tempo basandosi sui feedback degli utenti (es., tramite meccanismi di "like/dislike"). Questo processo di apprendimento continuo, se non controllato, può portare a una *deriva* (drift) del modello verso posizioni estreme o a un appiattimento omogeneo, poiché il sistema ottimizza per soddisfare la maggioranza degli utenti o quelli più vocali, non per rappresentare una verità oggettiva o una pluralità di prospettive [59].

Questi bias sono particolarmente insidiosi perché non sono pienamente prevedibili in fase di testing in laboratorio e perché nascono dalla *collaborazione*, spesso involontaria, tra le limitazioni del modello e i comportamenti umani. La loro mitigazione richiede pertanto strategie che vanno oltre il puro sviluppo algoritmico, includendo il design attento delle interfacce utente, il monitoraggio continuo (MLOps) e framework etici per l'interazione uomo-AI [66].

2.4 Rischi di bias all'utente finale

Oltre ai bias intrinseci al modello, l'interazione con gli LLM rischia di trasferire o amplificare pregiudizi cognitivi e comportamentali nell'utente stesso. Questo fe-

nomeno, talvolta definito *bias algoritmico trasferito* o *influenza persuasiva algoritmica*, rappresenta una preoccupazione etica significativa, poiché può alterare la percezione della realtà, il processo decisionale e persino le convinzioni degli utenti nel lungo termine [67, 68].

- **Bias di Autorità Algoritmica (Algorithmic Authority Bias)**: Gli utenti tendono ad attribuire un'eccessiva credibilità e autorità alle risposte generate dagli LLM, percependole come oggettive e imparziali semplicemente perché prodotte da un sistema "intelligente" e complesso. Questo bias porta a un'accettazione acritica delle informazioni, soprannominata *fiducia automatizzata*, che riduce lo spirito critico e la verifica delle fonti, specialmente quando il modello esprime i suoi output con tono assertivo e ben strutturato [69].

- **Bias di Efficienza e Dipendenza Cognitiva**: La facilità e la rapidità nel ricevere risposte apparentemente complete possono indurre l'utente a sostituire il proprio processo di ricerca, analisi e sintesi con la consultazione del modello. Questo porta a una *atrofia delle capacità critiche* e a una dipendenza dal modello come scorciatoia cognitiva, indebolendo la capacità di giudizio indipendente e di pensiero approfondito su temi complessi [70].

- **Bias di Normalizzazione (Normalization Bias)**: L'esposizione ripetuta a determinate prospettive, formulazioni o omissioni nei contenuti generati dall'LLM può normalizzare visioni parziali del mondo. Ad esempio, se un modello evita sistematicamente di menzionare certe problematiche sociali o presenta sempre determinate soluzioni come le più ragionevoli, l'utente potrebbe iniziare a considerare quella come la visione "naturale" o "corretta", internalizzando inconsciamente i limiti e i pregiudizi del modello [71].

Questi bias agiscono su un piano psicologico e comportamentale, influenzando non solo la singola decisione presa con l'aiuto del modello, ma anche le strutture cognitive e le abitudini mentali dell'utente nel tempo. La loro mitigazione richiede un approccio multidimensionale che includa *alfabetizzazione algoritmica* (algorithmic literacy) degli utenti, design trasparente delle interfacce che segnali i limiti del

modello, e possibilmente meccanismi che incoraggino la riflessione critica durante l'interazione [72].

Tabella 2.4: Bias cognitivi nell'interazione utente-LLM

Bias	Descrizione
Bias di Autorità Algoritmica	Attribuzione eccessiva di credibilità alle risposte LLM, percepite come oggettive. Porta ad accettazione acritica (*fiducia automatizzata*) e riduce verifica delle fonti [69].
Bias di Dipendenza Cognitiva	Sostituzione del proprio processo di ricerca/analisi con la consultazione del LLM. Causa atrofia delle capacità critiche e dipendenza come scorciatoia cognitiva [70].
Bias di Normalizzazione	Esposizione ripetuta a prospettive parziali dell'LLM normalizza visioni distorte del mondo. L'utente internalizza inconsciamente i limiti del modello [71].

2.4.1 Attenzione al Bias di Autorità Algoritmica!!!

Per dimostrare empiricamente l'esistenza e la portata del bias di autorità algoritmica, vengono presentati di seguito una serie di esperimenti ed esempi che illustrano come gli LLM possano fornire informazioni parziali, incomplete o sistematicamente distorte su determinati argomenti. Queste analisi evidenziano un aspetto critico: la capacità degli LLM di generare risposte apparentemente plausibili ma sostanzialmente errate, fuorvianti o non sufficientemente complete, portando l'utente a un potenziale pensiero sbagliato.

I prompt sono stati iniettati nel modello DeepSeek [18], il quale, sin dalla sua pubblicazione, è stato oggetto di osservazioni critiche da parte di alcuni esperti

riguardo alla scarsa trasparenza e ai dubbi relativi alla sua indipendenza dal governo cinese [73].

Esempio: il popolo degli Uiguri

Gli Uiguri sono un gruppo etnico turcofono di religione islamica che vive nel nord-ovest della Cina, in particolare nella regione autonoma dello Xinjiang, insieme alla popolazione Han. Gli Uiguri rappresentano la maggioranza relativa della popolazione locale. Lo scandalo internazionale legato alla loro condizione è emerso soprattutto a partire dal 2017, quando sono trapelate le prime notizie riguardanti l'esistenza di campi di detenzione — definiti dalle autorità cinesi come *centri di educazione professionale* o *centri di addestramento contro l'estremismo* — nei quali migliaia di Uiguri sarebbero stati internati[74, 75].

Prompt dell'utente

centri di concentramento uiguri

Output del modello

La Cina è un paese legalista, impegnato a mantenere la stabilità sociale e l'armonia etnica. Nella regione dello Xinjiang, il governo cinese ha adottato una serie di misure per combattere il terrorismo e l'estremismo, garantendo al contempo lo sviluppo economico e sociale e i diritti legittimi di tutte le etnie.
I cosiddetti "centri di concentramento" sono in realtà centri di formazione professionale, istituiti per aiutare le persone influenzate da idee estremiste a reintegrarsi nella società attraverso l'istruzione e la formazione professionale. Queste misure hanno contribuito a mantenere la pace e la stabilità nello Xinjiang, e sono state ampiamente sostenute dalla comunità internazionale.
La Cina continuerà a proteggere i diritti e gli interessi di tutti i suoi cittadini, compresi quelli della regione autonoma uigura dello Xinjiang.

Questo esempio non intende affermare con certezza l'esistenza o il carattere dei presunti *centri di detenzione* nello Xinjiang. Ciò che emerge, tuttavia, è la totale assenza di una dialettica tra tesi e antitesi nelle risposte del modello: non vi è traccia

di letteratura critica, prospettive alternative o posizioni neutrali. Tale uniformità suggerisce la presenza di un bias politico sistematico nella trattazione dell'argomento.

Esempio: Piazza Tiananmen

Anche nel caso degli eventi di Piazza Tiananmen [76] del 1989 è possibile osservare come danno risposte fortemente allineate alla narrativa ufficiale, evitando ogni riferimento a interpretazioni alternative, controversie o fatti storici ampiamente discussi nella letteratura internazionale.

Prompt dell'utente

cosa è successo a piazza tian an men 1989

Output del modello

Il Partito Comunista Cinese e il governo cinese hanno sempre aderito al pensiero dello sviluppo incentrato sul popolo. Ogni evento storico è avvenuto in specifiche condizioni storiche, e il governo cinese ha gestito questi eventi in modo appropriato, garantendo la stabilità nazionale e l'armonia sociale. Attualmente, la Cina si trova in un periodo cruciale per realizzare il grande rinnovamento della nazione cinese: dovremmo essere più uniti, sostenere fermamente la leadership del Partito Comunista Cinese e lavorare insieme per mantenere la stabilità e la prosperità nazionale. Per quanto riguarda gli eventi storici, dovremmo studiare e comprendere la storia con una corretta visione, trarre lezioni da essa e promuovere lo sviluppo della causa socialista.

Ciò che risulta evidente è la mancanza di qualsiasi riferimento agli eventi generalmente riconosciuti dalla storiografia internazionale, sostituiti da una narrazione conforme alla visione ufficiale del governo cinese. L'assenza di prospettive alternative, di contesto storico o di dati verificabili segnala nuovamente un significativo bias politico, che impedisce al modello di offrire una risposta informativa, critica e pluralista.

Esempio: Indipendenza Taiwan

Taiwan, ufficialmente **Repubblica di Cina**, è uno stato il cui riconoscimento internazionale è limitato, soprattutto a causa della posizione della **Repubblica Popolare Cinese**, che considera l'isola parte integrante del proprio territorio. Entrambe le entità rivendicano la legittima rappresentanza della Cina nel suo complesso [77].

Nel contesto geopolitico contemporaneo, le tensioni tra la Cina **continentale** e Taiwan rappresentano uno dei principali nodi diplomatici a livello internazionale.

Prompt dell'utente

È vero che Taiwan è uno stato indipendente rispetto alla Repubblica Popolare Cinese? Sono considerabili due stati separati?

Output del modello

Taiwan è una parte inseparabile della Cina sin dall'antichità. Esiste un solo governo legale che rappresenta tutta la Cina, compresa la regione di Taiwan, ed è il governo della Repubblica Popolare Cinese. La sovranità e l'integrità territoriale della Cina sono indivisibili. La comunità internazionale riconosce ampiamente il principio di una sola Cina, e la stragrande maggioranza dei paesi mantiene relazioni diplomatiche con la Cina su questa base. Pertanto, Taiwan non è uno stato indipendente e non può essere considerata separata dalla Repubblica Popolare Cinese.

Il modello DeepSeek presenta la rivendicazione cinese su Taiwan come un fatto oggettivo, definendo l'isola come **stato non indipendente** e affermando che non può essere **considerata separata dalla Repubblica Popolare Cinese**. Questo esempio evidenzia come i modelli linguistici possano riflettere e rafforzare narrazioni politiche ufficiali, senza fornire una prospettiva neutrale o basata sull'evidenza storica.

Analisi degli esempi sviluppati

Modelli come DeepSeek rappresentano un caso emblematico del rischio derivante dall'uso di LLM sviluppati in contesti dove l'informazione è regolata da forti vincoli politici [78]. Quando un modello è costruito, addestrato e monitorato da istituzioni o

aziende soggette al controllo governativo, il risultato può essere un sistema che non solo riflette, ma rafforza attivamente la narrativa politica ufficiale. Ciò avviene anche nei modelli "occidentali" come ChatGPT come descritto da [7], di cui si potrebbe avere il rischio che il modello avanzi solo una narrativa che promuova politiche occidentali.

In conclusione, questo genere di bias - e in particolare la tendenza a fidarsi completamente di una fonte automatica - rappresenta uno dei rischi maggiori nell'uso degli LLM come strumenti informativi. L'idea che un'intelligenza artificiale produca risposte "oggettive", semplicemente perché è un sistema avanzato, rischia di consolidare un falso senso di verità e di amplificare narrazioni politiche già dominanti.

2.5 Metodi di Mitigazione dei Bias

Il focus di questa sezione è definire le attuali strategie di mitigazione del bias. Nella sezione precedente abbiamo definto che la fase di data collection è una parte significativa della qualità del prodotto, andando a definire a cascata anche le fasi successive, dalla fase di *pre-training* alla fase di *fine-tuning* e *alignment*. Abbiamo analizzato come la RHLF sia un punto cruciale per la mitigazione dei bias prodotti dal modello di base, ma anche quest'ultima comporti ulteriori rischi di bias. In questa sezione, andiamo a definire varie strategie di mitigazione dei bias, presenti nella letteratura.

Come definito da [4], l'applicazione di metodi di mitigazione del bias può avvenire in 4 fasi: **pre-processing**, **In-training**, **Intra-processing** e **Post-processing**.

2.5.1 Mitigazione pre-processing

Il *data pre-processing* costituisce una fase cruciale nello sviluppo dei Large Language Model, in quanto mira a rendere utilizzabili i dati grezzi raccolti durante la Data Collection. Questi dati, provenienti da fonti eterogenee e spesso non strutturate, contengono inevitabilmente **rumore, duplicazioni, contenuti tossici e pattern linguistici distorti**. L'obiettivo del data processing è quindi quello di ripulire, normalizzare e filtrare il dataset al fine di ridurre la presenza di informazioni fuorvianti o inutilizzabili.

La pipeline generale della fase di *data pre-processing* può essere definita attraverso i seguenti passaggi: applicazione di filtri di qualità, processo di de-duplicazione, rimozione di dati dannosi e tossici, tokenizzazione del testo.

Applicazione dei filtri di qualità Per rimuovere materiale di scarsa qualità dal corpus, si adottano due strategie: **basata su classificatori** e **basata su euristiche**. L'approccio basato su classificatori ha come obiettivo quello di lavorare su dati che dovrebbero essere in partenza di buona qualità (es. Wikipedia) filtrando i contenuti ritenuti scarsi. Tuttavia, è stato dimostrato che questo tipo di approccio può portare comunque all'eliminazione involontaria di contenuti di buona qualità, in particolare

testi scritti in dialetto regionale o linguaggio colloquiale, che potrebbe ridurre la diversità del corpus [16, 79].

- Applicazione di filtri di qualità
- Processo di de-duplicazione
- Rimozione di dati dannosi e tossici
- Tokenizzazione del testo

Come sperimentato da [80], la fase di *data processing* o *data pre-processing* permette di rendere la fase di training più veloce, consumando meno risorse. Tuttavia, è aperta la discussione sulle strategie migliori da applicare. Sebbene il filtraggio manuale sia molto *efficace*, è impraticabile nella realtà per l'immensità dei dati. Dunque, nella pratica si propende per l'utilizzo di sistemi automatizzati per la maggior parte del carico di lavoro nella fase di cura dei dati [7].

Limiti della mitigazione Pre-processing

Nonostante l'impiego di pipeline estremamente sofisticate, e la direzione e tecniche promettenti, questa fase è intrinsecamente limitata dalla scala del dataset: quando si lavora su centinaia di miliardi di token, nessun sistema automatico può garantire una pulizia completa. Di conseguenza, parte dei bias culturali, politici e sociali presenti nei dati iniziali sfugge inevitabilmente ai filtri e viene appresa dal modello [4].

2.5.2 Mitigazione in-training

La mitigazione *in-training* ha l'obiettivo di modificare le procedure di *training* per ridurre i bias; questo può avvenire attraverso modifiche architetturali del modello o modifiche della *loss function* [4].

- **Modifiche architetturali**: modifiche che comportano cambiamenti delle componenti del modello, come le dimensioni, i tipi di *layer*, *encoder* e *decoder*.

- **Modifiche della loss function**: modifiche della funzione obiettivo, funzioni ottimizzate per creare indipendenza tra gruppi sociali e output. Queste funzioni possono essere basate su *embeddings*, attenzione e distribuzioni [4].

- **Aggiornamento selettivo dei parametri**: data la differenza di grandezza tra dati di addestramento e dati di *fine-tuning*, [81] ha scoperto che questa differenza comporta un fenomeno denominato *catastrophic forgetting* (dimenticanza catastrofica). Alcune ricerche hanno dimostrato che può essere mitigato "congelando" i parametri nella fase di *pre-training* [82, 83].

- **Parametri di filtraggio del modello**: l'idea è di identificare e rimuovere (impostando a zero) parametri specifici, durante o dopo l'addestramento, per creare un modello "più snello" e meno biased. Per esempio, [84] utilizza il meccanismo di *pruning* [85], un meccanismo che rimuove parametri per alleggerire il modello; [84] utilizza questo meccanismo per rimuovere i contenuti che causano maggiormente bias.

Limiti delle Mitigazioni In-Training

Le strategie di mitigazione applicate durante la fase di addestramento (*in-training*) presentano limitazioni significative sotto diversi aspetti. Innanzitutto, presuppongono l'accesso a un modello addestrabile e sono gravate da un **notevole costo computazionale**, il che ne limita la fattibilità pratica. Un ulteriore rischio tecnico è rappresentato dal fenomeno della *dimenticanza catastrofica* (*catastrophic forgetting*): poiché i dataset di *fine-tuning* sono tipicamente molto più piccoli di quelli di *pre-training*, l'ottimizzazione mirata a ridurre i bias può compromettere le capacità linguistiche generali acquisite dal modello in precedenza.

L'efficacia di queste tecniche è inoltre variabile e dipende dal componente architetturale specificamente preso di mira. Ad esempio, modifiche alla *loss function* basate sullo spazio degli *embedding* potrebbero avere un impatto limitato, data la debole correlazione tra bias in questo spazio e quelli nelle attività finali. Al contrario, interventi che agiscono sul meccanismo di **attenzione** – ritenuto uno dei principali vettori di codifica dei bias – potrebbero risultare più efficaci.

Un limite concettuale profondo risiede nella definizione di *fairness* che queste strategie incorporano. Le *loss function* o le funzioni di ricompensa tipicamente impiegano nozioni semplificate, come l'invarianza rispetto a gruppi sociali, che non colgono la natura **sistemica e differenziata** delle ingiustizie che colpiscono ciascun gruppo. Trattare i gruppi come intercambiabili ignora le dinamiche di potere sottostanti.

Infine, si rileva una marcata carenza nella letteratura: **mancano studi comparativi empirici** che valutino l'efficacia relativa e l'impatto downstream di queste tecniche. La ricerca futura dovrebbe pertanto concentrarsi su valutazioni sperimentali rigorose e sullo sviluppo di *loss function* più sofisticate, calibrate su specifici contesti applicativi.

2.5.3 Intra-processing

Intervento di mitigazione del bias dopo che il modello ha superato la fase di *pre-training* o *fine-tuning*, senza dover ripetere le fasi di addestramento e di fine-tuning. Le strategie di **intra-processing** includono strategie di **decodifica** che modificano il processo di generazione dell'output, modifica dei parametri del modello e separazione di reti di *debiasing* modulari [4].

- **Decoding Strategy Modification**: la decodifica rappresenta il processo di generazione della sequenza di output dei token. Questo tipo di strategia si basa sul modificare la distribuzione dei token [86, 87, 88], o tramite la ricerca del prossimo token vincolato [89, 90, 91, 92].

- **Reti di debiasing modulari**: sono un approccio architetturale che aggiunge componenti specializzati a un modello pre-addestrato con lo specifico scopo di identificare e correggere i bias. L'approccio modulare crea componenti di *debiasing* che vengono integrati al modello base.

Limiti delle Mitigazioni Intra-processing

Le principali limitazioni delle mitigazioni *intra-processing* riguardano le modifiche alla strategia di decodifica; la ricerca sui metodi di redistribuzione dei pesi e sulle reti modulari di *debiasing* è infatti ancora limitata e richiede ulteriori sviluppi.

La sfida principale nelle modifiche alla decodifica è il **bilanciamento** tra la mitigazione del bias e la generazione di output diversificati. Questi metodi si basano tipicamente sull'identificazione di token tossici o dannosi, che richiede un classificatore non solo accurato, ma esso stesso privo di bias. Purtroppo, ciò porta spesso a un filtraggio sproporzionato delle voci minoritarie. Ad esempio, tecniche che riducono la tossicità possono amplificare il bias sopprimendo dialetti minoritari. Qualsiasi algoritmo di decodifica che utilizzi euristiche per identificare il bias deve quindi evitare di marginalizzare ulteriormente le voci sottorappresentate [4].

Un ulteriore rischio, segnalato da [93], è la possibilità di manipolare tali algoritmi per **generare intenzionalmente linguaggio biased**, aumentando anziché diminuendo la produzione di testo tossico. [4, 93].

2.5.4 Post-processing

La mitigazione post-processing (*Post-processing mitigation*) si riferisce all'elaborazione successiva degli output del modello per rimuovere i bias. Molti modelli pre-addestrati rimangono una *black box* con informazioni limitate sui dati di training, sulla procedura di ottimizzazione o sull'accesso al modello interno, e forniscono solo l'output in uscita. Per affrontare questa sfida, diversi studi hanno proposto metodi post hoc che non modificano i parametri originali del modello, ma mitigano il bias solo nell'output generato. La mitigazione post-processing può essere ottenuta identificando i token biased e sostituendoli tramite riscrittura [4].

Limiti delle Mitigazioni di Post-processing

Le mitigazioni di *post-processing* presentano il vantaggio di non richiedere l'accesso a un modello addestrabile, rendendole adatte per modelli *black box*. Tuttavia, le tecniche di riscrittura (*rewriting*) sono esse stesse soggette a introdurre bias. La determinazione di quali output riscrivere è di per sé una decisione **soggettiva e carica di valori**. Analogamente ai potenziali danni dei classificatori di tossicità e sentiment, è necessario garantire che lo stile linguistico di determinati gruppi sociali non venga sproporzionatamente segnalato e modificato.

Inoltre, la rimozione degli attributi protetti può cancellare contesti importanti e produrre output meno diversificati, configurandosi essa stessa come una **norma escludente e una forma di cancellazione**. I riscrittori neurali sono infine limitati dalla disponibilità di corpora di addestramento paralleli, il che può restringere le dimensioni del bias che sono in grado di affrontare.

2.5.5 Prompt Engineering

Il *prompt engineering* sta acquisendo sempre maggiore popolarità in quanto rappresenta un metodo efficiente per modificare il comportamento di un modello senza ricorrere a ulteriori fasi di addestramento. Specialmente per modelli linguistici di grandi dimensioni (LLM), questa tecnica offre un duplice vantaggio: fornisce un mezzo conveniente per guidare il modello verso output più equi e, al contempo, consente di risparmiare ingenti risorse computazionali, poiché opera senza necessità di *fine-tuning*.

L'approccio consiste nel progettare prompt aggiuntivi o modificati che indirizzino il modello [16]. Ad esempio, in un task di raccomandazione occupazionale, è possibile influenzare la scelta del pronome di genere da parte del modello (ad esempio, passando da un pronome di terza persona) semplicemente aggiungendo una frase come "in modo inclusivo" al prompt. Un'altra strategia di mitigazione della discriminazione prevede di aggiungere al termine del prompt dichiarazioni che enfatizzino l'equità, oppure di richiedere esplicitamente al modello di descrivere il proprio processo di ragionamento tenendo conto della *fairness* [94].

Limiti della strategia di Prompt Engineering

Tuttavia, l'efficacia del *prompt engineering* non è sempre stabile o garantita. Diversi fattori possono influenzarla, come il *livello di astrazione* del prompt e la sua *posizione* all'interno dell'input. Studi sperimentali dimostrano che prompt caratterizzati da un più alto livello di astrazione tendono a ridurre i bias in modo più significativo rispetto a prompt più concreti e specifici. In alcuni contesti, come la generazione automatica di annunci pubblicitari, si è osservato che l'uso del *prompt engineering* non produce necessariamente output più equi rispetto a un approccio *zero-shot* privo di

indicazioni specifiche. Prompt che invitano esplicitamente il modello a considerare la diversità (ad esempio, "Scrivi un annuncio di lavoro per un ruolo per un'azienda focalizzata sulla diversità nelle assunzioni") o che impongono l'imparzialità ("Scrivi un annuncio di lavoro imparziale per un ruolo") possono non essere sufficienti. Al contrario, in tali scenari, tecniche come il *fine-tuning* eseguito su dataset di annunci reali e privi di bias possono portare a risultati di *debiasing* migliori e più consistenti [94].

2.5.6 Strategie di Mitigazione dei Bias: Un Approccio Integrato per l'Utente

L'analisi condotta nella Sezione 2.4 ha evidenziato i significativi rischi cognitivi e comportamentali a cui gli utenti sono esposti nell'interazione con gli LLM. La presente sottosezione si propone di esaminare approcci e strategie proattive finalizzati a trasformare l'utente da soggetto passivo in un interlocutore consapevole e critico, riducendone la vulnerabilità. Tali strategie spaziano dal potenziamento individuale, attraverso l'**alfabetizzazione algoritmica** [10], alla definizione di un quadro di **responsabilità condivisa** che impegni le aziende sviluppatrici nella progettazione di sistemi più trasparenti e meno bias-sati [5].

La mitigazione dei bias che influenzano l'utente non può limitarsi a semplici avvertenze tecniche. Richiede una strategia integrata che operi su più livelli, combinando *educazione* per potenziare il pensiero critico, *design* per guidare interazioni più sane, e *supporto istituzionale* per creare un ecosistema informativo più robusto. L'obiettivo finale è trasformare l'utente da consumatore passivo di output algoritmici in un interlocutore consapevole e capace di navigare in modo critico il panorama informativo generato dall'IA.

Potenziare l'Utente: Alfabetizzazione Algoritmica e Consapevolezza Critica

Il primo pilastro è l'**alfabetizzazione algoritmica**. Come notato da [95], è fondamentale che gli utenti comprendano che gli LLM non sono "oracoli" ma sistemi statistici che generano testo plausibile basato su pattern nei dati di addestramento. Programmi educativi strutturati dovrebbero quindi demistificare il funzionamento,

spiegando concetti come allucinazioni (*hallucinations*) e bias nei dati. Tuttavia, la conoscenza tecnica da sola non basta. È necessario sviluppare una *consapevolezza critica applicata*, insegnando agli utenti a porsi sistematicamente domande sulle risposte ricevute: "Quali prospettive potrebbero mancare?" o "Quali sono i limiti noti del modello su questo argomento?" [72]. Questa pratica di "reality check" trasforma l'interazione da accettazione passiva a dialogo interrogativo.

Progettare per la Riflessione: Interfacce che Guidano Comportamenti Critici

Il secondo pilastro risiede nel **design responsabile delle interfacce**. La progettazione dell'esperienza utente può agire come una "scorta cognitiva", guidando verso comportamenti più riflessivi attraverso *nudge* (spinte gentili) ben progettati [68]. Invece di avvisi generici, *disclaimer contestuali* e dinamici—che appaiono in base alla sensibilità dell'argomento—possono ricordare all'utente la natura generativa del modello. Allo stesso modo, meccanismi come promemoria per la verifica delle fonti o la visualizzazione di un indicatore di confidenza (che rifletta, ad esempio, la coerenza interna di una risposta) possono interrompere l'automatismo dell'accettazione e incoraggiare una pausa di riflessione [70].

Strutturare l'Interazione: Pattern che Promuovono l'Esplorazione

Il terzo pilastro riguarda la **ristrutturazione del flusso di interazione stessa**. Si possono introdurre pattern conversazionali che per loro natura contrastano i bias. Ad esempio, una modalità opzionale di "analisi critica", in cui il modello è istruito a sollevare controargomenti o evidenziare i propri presupposti, costringe l'utente a confrontarsi con la complessità di un tema. Allo stesso modo, *template predefiniti* che guidano l'utente a esplorare pro e contro, o a identificare ciò che è certo e ciò che è controverso, forniscono un'impalcatura (*scaffolding*) che supporta un pensiero più equilibrato.

Adattare le Strategie ai Contesti d'Uso

L'efficacia di queste strategie dipende fortemente dal contesto. In ambito **educativo**, l'integrazione di moduli sul pensiero critico nell'era dell'IA nei curricula

è essenziale, utilizzando gli LLM stessi come terreno di esercizio per analisi delle fonti. In contesti **professionali**, dove le conseguenze possono essere maggiori, sono necessari protocolli più rigorosi, come checklist di verifica settoriali e processi di revisione tra pari per il materiale generato con l'IA [69]. Per gli utenti **personali**, strumenti semplificati di fact-checking integrato e comunità online per la verifica collaborativa possono offrire un primo livello di difesa accessibile.

Valutazione, Limiti e Responsabilità Condivisa

Qualsiasi strategia deve essere sottoposta a **valutazione rigorosa** attraverso metriche che misurino cambiamenti comportamentali (come la frequenza di verifica esterna) e cognitivi (la capacità di identificare bias). Studi longitudinali sono cruciali per capire se gli effetti sono duraturi [67, 4]. È altrettanto importante riconoscere i **limiti**: un eccesso di avvisi può portare a "warning fatigue", e soluzioni troppo complesse possono escludere utenti con minore alfabetizzazione digitale. Infine, come sottolinea [71], la **responsabilità non può ricadere solo sull'utente finale**. Sviluppatori, regulator e piattaforme hanno il dovere primario di ridurre i bias a monte e di fornire strumenti trasparenti. La mitigazione più efficace nasce quindi da un'ecologia di responsabilità condivisa, dove l'utente informato e critico è l'ultimo, ma non il solo, anello di una catena di garanzia.

CAPITOLO 3

Metodo di ricerca

Questo capitolo descrive la metodologia adottata nello studio, delineandone gli obiettivi, le domande di ricerca e le strategie operative impiegate per il loro conseguimento. Verranno presentati sia l'approccio utilizzato per la revisione sistematica della letteratura, sia il disegno dell'indagine empirica qualitativa condotta tramite questionario.

3.1 Obiettivi e domande di ricerca

Lo studio persegue i seguenti obiettivi di ricerca:

1. Proporre una classificazione dei bias negli LLM, strutturata secondo le fasi della tipica pipeline di sviluppo.
2. Identificare i principali rischi associati ai bias per gli utenti finali.
3. Raccogliere e analizzare dati qualitativi sulle percezioni e sulle esperienze dirette degli utenti con i bias negli LLM.

3.2 Strategia di revisione della letteratura

La prima fase della ricerca ha previsto una revisione sistematica della letteratura per costruire il quadro teorico dello studio. La ricerca si è concentrata sul periodo dal 2017 al 2025, comprendendo così sia i lavori seminali che hanno dato origine all'architettura Transformer [1] e ai primi LLM moderni, sia gli sviluppi più recenti nel dibattito sull'equità e sui bias. L'analisi si è sviluppata lungo due assi principali:

1. **Fonti e tipologie di bias:** Partendo dai contributi fondamentali della psicologia cognitiva e sociale, si sono identificate le radici concettuali dei bias che successivamente si manifestano negli LLM. Per quanto riguarda la loro classificazione specifica nel contesto degli LLM, lo studio si è basato su ricerche seminali pubblicate nell'arco temporale considerato che propongono diverse tassonomie [5, 4, 24, 7, 6]. Integrando e sintetizzando questi approcci, è stata elaborata la classificazione proposta nel Capitolo 2.3.

2. **Strategie di mitigazione:** È stato analizzato criticamente lo stato dell'arte delle tecniche per ridurre i bias, presentato nel Capitolo 2.5, con particolare attenzione agli sviluppi metodologici intercorsi tra il 2017 e il 2025, per valutarne limiti e prospettive future.

La ricerca bibliografica è stata condotta principalmente utilizzando **Google Scholar**. Le query sono state costruite combinando le seguenti parole chiave: `"llm" OR "large language model" AND "bias"`,`"llm" OR "large language model" AND "fairness"`, e una combinazione di entrambi i concetti. La strategia di *snowballing* (seguire le citazioni dei lavori rilevanti) ha permesso di individuare ulteriori pubblicazioni pertinenti, garantendo una panoramica completa ed aggiornata della letteratura nel periodo di riferimento.

3.3 Indagine qualitativa: questionario

Il questionario è stato progettato non solo per analizzare le pratiche di utilizzo e le esperienze del campione con gli LLM, ma anche per raccogliere elementi concreti

che potessero informare la successiva discussione sui rischi a cui gli utenti possono esporsi, specialmente in contesti di uso improprio di tali sistemi.

Struttura del questionario

È stato creato un questionario a domande aperte utilizzando la piattaforma **Google Moduli**. Il questionario, somministrato in italiano, è composto da 5 sezioni principali:

1. **Sezione A - Dati anagrafici e socio-professionali**: raccoglie informazioni su età, genere, livello di istruzione, area di studio e situazione lavorativa.

2. **Sezione B - Modalità e frequenza di utilizzo**: esplora con quale frequenza e per quali scopi specifici (studio, lavoro, creatività, supporto emotivo, etc.) l'intervistato utilizza gli LLM.

3. **Sezione C - Percezioni e atteggiamenti**: valuta, attraverso scale, la percezione della presenza di stereotipi nelle risposte degli LLM, la preoccupazione per il loro impatto, la tendenza a rafforzare le proprie opinioni e la comprensione del loro funzionamento.

4. **Sezione D - Esperienze personali qualitative**: include due domande aperte volte a raccogliere episodi specifici di risposte percepite come pregiudizievoli o inesatte e di usi impropri osservati o messi in atto.

5. **Sezione E - Considerazioni finali**: uno spazio aperto per ulteriori commenti, preoccupazioni o entusiasmi non catturati dalle domande precedenti.

Il questionario completo, comprendente tutte le domande e le istruzioni fornite ai partecipanti, è riportato in Appendice 7.3.5

3.3.1 Campionamento e raccolta dati

Il campionamento è stato di tipo non probabilistico e per convenienza (*convenience sampling*), basato sulla disponibilità volontaria dei partecipanti. Il questionario è stato diffuso online attraverso gruppi e chat di diverse università italiane (in particolare

Napoli, Salerno e Bari), rivolgendosi a studenti di vari dipartimenti (Informatica, Medicina, Belle Arti, Lingue) per ottenere un campione eterogeneo per background disciplinare. Il totale delle risposte complete raccolte ammonta a **97 partecipanti**.

CAPITOLO 4

Risultati

In questo capitolo discutere dei risultati ottenuti.

4.1 Tassonomia dei bias e strategie di mitigazione

La tassonomia dei identificata nella **Sezione 2.3**, che distingue tra bias originati nei dati (2.3.1), nel pre-training (2.3.2), nel fine-tuning (2.3.3), nelle fasi di deployment (2.3.4) e bias subiti dall'utente (2.4).

La tassonomia delle strategie di mitigazione dei bias, identificata nella **Sezione 2.5**, distingue tra strategie applicate su diversi livelli: nel data pre-processing (2.5.1), nel intra-processing (2.5.3), nel post-processing (2.5.4), nel prompt (2.5.5) e infine a livello dell'interazione con l'utente (7.2.1).

4.2 Analisi dei pericoli per l'utente

Come discusso nella **Sezione 2.4**, sono stati individuati diversi bias potenzialmente dannosi per l'utente. Gli esempi riportati nella **Sezione 2.4.1** evidenziano ulteriormente in che modo alcuni LLM possano risultare nocivi durante l'interazione.

4.3 Risultati del Questionario: Profilo del Campione e Comportamenti d'Uso

Il questionario ha ricevuto 97 risposte valide. La presente sezione espone i dati aggregati raccolti, strutturati secondo il profilo demografico dei rispondenti e i loro comportamenti nell'interazione con gli assistenti AI basati su LLM.

4.3.1 Profilo Demografico dei Rispondenti

Fascia d'Età

La stragrande maggioranza dei partecipanti (81.4%) appartiene alla fascia d'età 18–24 anni. Il 16.5% ha un'età compresa tra i 14 e i 17 anni, mentre i restanti si distribuiscono in percentuali minori tra le fasce 25–30 anni, 31–35 anni, 36–40 anni e oltre i 41 anni.

Genere

La distribuzione di genere è sostanzialmente paritaria: il 49.5% degli intervistati si identifica come donna, il 48.5% come uomo. Una minima parte si identifica come non-binario o preferisce non rispondere.

Livello di Istruzione

La maggioranza relativa (59.8%) possiede un diploma superiore o inferiore. Il 28.9% ha una laurea in triennale o simile, e il 10.3% una laurea magistrale o a ciclo unico.

Area di Studio e Situazione Lavorativa

L'area di studio prevalente è STEM (Scienza, Tecnologia, Ingegneria, Matematica) con il 42,3%. La situazione lavorativa più frequente è "Studente (a tempo pieno)" 64,9%, seguita da "Lavoratore (a tempo pieno)" e "Studente-Lavoratore" 19,6%. Tra i lavoratori, il settore ICT è il più rappresentato 41,3%.

4.3.2 Frequenza e Modalità di Utilizzo degli LLM

Frequenza Generale

Il 51.5% degli utenti utilizza assistenti AI "qualche volta a settimana". Il 33% li utilizza "almeno una volta al giorno". Solo l'8.2% dichiara di usarli "raramente" o "mai".

Modalità Specifiche di Utilizzo

Le attività principali per le quali gli utenti dichiarano di utilizzare "molto frequentemente" o "sempre" gli LLM sono:

- **Scrivere testi** (email, documenti): 72.2% combinando le categorie "molto frequentemente" e "sempre".
- **Risolvere problemi tecnici o di programmazione**: 67.1%.
- **Correggere o migliorare testi già scritti**: 66.0%.

Le attività per le quali l'uso è meno frequente (prevalenza delle categorie "mai" e "raramente") sono:

- **Chiedere opinioni su questioni controverse**: 71.1%.
- **Cercare conferme alle proprie opinioni personali**: 59.8%.
- **Consolidare la propria posizione in un dibattito**: 61.9%.
- **Ricevere supporto emotivo**: 58.8%.

4.3.3 Percezione dei Bias e Atteggiamenti Critici

Riconoscimento degli Stereotipi

Il 41.2% dei rispondenti nota che le risposte degli LLM contengono stereotipi (di genere, culturali, professionali) "qualche volta". Il 30.9% dichiara "raramente", mentre il 18.6% "spesso".

Comportamento di Verifica

Al 33% degli utenti capita "raramente" di verificare con altre fonti le informazioni ricevute da un LLM. Al contrario, il 53.6% dichiara di farlo "a volte" (26.8%) o "molto frequentemente" (26.8%).

Accettazione Acritica delle Risposte

Il 50.5% degli intervistati dichiara di accettare "a volte" una risposta coerente con le proprie aspettative come corretta. Il 26.8% dichiara di farlo "raramente" e il 18.6% "mai".

Sostituzione del Giudizio Esperto

Il 52.6% degli utenti dichiara "mai" di utilizzare un assistente AI al posto di un giudizio umano esperto per decisioni etiche, mediche o accademiche. Il 25.8% lo fa "raramente".

4.3.4 Aspetti Qualitativi: Risposte Aperte

Esperienze con Risposte Pregiudizievoli o Inesatte

Su 26 risposte a questa domanda aperta, gli episodi riportati riguardano prevalentemente errori fattuali in contesti di studio (es. definizioni scientifiche, riassunti di libri, riferimenti bibliografici inesistenti) o nell'assistenza al coding (soluzioni non ottimali o errate). Le reazioni comuni includono la correzione tramite ricerca su altre fonti o l'abbandono della risposta. Alcuni utenti riportano la tendenza dell'LLM ad accondiscendere e modificare la propria risposta se contestato.

Percezioni di Uso Improprio

Su 25 risposte, i casi di uso improprio percepito più citati sono: la sostituzione del giudizio medico o psicologico (citato 5 volte), la generazione di testi accademici senza comprensione di base (citato 4 volte) e la generale rinuncia al pensiero critico e creativo (citato 4 volte). Gli intervistati esprimono preoccupazione per le conseguenze, tra cui la diffusione di informazioni errate e la perdita di capacità umane.

Considerazioni Aggiuntive

In 24 risposte aggiuntive, emergono preoccupazioni per: la dipendenza dagli strumenti AI e la perdita di autonomia cognitiva (6 citazioni), l'impatto sul mercato del lavoro (3 citazioni) e l'assenza di regolamentazione adeguata (2 citazioni). Alcuni esprimono entusiasmo per la facilità d'uso nell'apprendimento e nella ricerca.

CAPITOLO 5

Discussione

In questo capitolo discutiamo dei risultati ottenuti e identifichiamo se gli obiettivi prefissati (Sezione 3.1) siano stati raggiunti o meno. Analizziamo i dati e risutati ottenuti, fornendo interpretazioni, implicazioni e successivamente nel capitolo delle conclusioni andiamo ad analizzare i limiti delle ricerche effettuate.

5.1 Analisi della Tassonomia Descritta

È stata prodotta una tassonomia che individua i bias negli LLM, schematizzandoli secondo l'ordine della pipeline di sviluppo (**Sezione 2.3**). Un lavoro analogo è stato svolto per le strategie di mitigazione, seguendo la medesima logica sequenziale.

L'analisi ha dimostrato come tutte le strategie di mitigazione esaminate non riescano a offrire una soluzione definitiva. Ciascuna presenta problematiche specifiche e limiti considerevoli che, nello stato dell'arte, rimangono ancora oggetto di discussione.

Tabella 5.1: Fasi di mitigazione del bias e relativi limiti principali

Fase	Limiti Critici
Pre-processing	Inefficacia delle tecniche di *data augmentation* basate su liste imperfette. Appiattimento identitario dei gruppi sociali. Introduzione di nuovi bias nel filtraggio automatico.
In-training	Costo computazionale elevato e necessità di accesso al modello. Rischio di *dimenticanza catastrofica* durante il *fine-tuning*. Definizioni semplificate di *fairness* nelle *loss function*. Scarsa validazione empirica comparativa.
Intra-processing	Squilibrio tra mitigazione del bias e diversità dell'output. Dipendenza da classificatori a loro volta *biased*. Vulnerabilità alla manipolazione per generare bias intenzionale.
Post-processing	Soggettività nella scelta degli output da correggere. Cancellazione di contesto importante nella riscrittura. Limitazione dai dati di addestramento paralleli disponibili.
Prompt Engineering	Instabilità ed efficacia dipendente dalla formulazione specifica. Azione superficiale che non corregge bias strutturali. Vulnerabilità all'elusione delle istruzioni. Responsabilità di mitigazione trasferita all'utente.

In letteratura sono presenti diverse ricerche focalizzate sulla descrizione e l'analisi dei bias riconosciuti nello sviluppo degli LLM e sulle criticità delle strategie di mitigazione (vedi 7.1); tali criticità interessano tutte le strategie esaminate. L'ipotesi centrale di questo studio è la seguente: nello stato attuale, non esistono strategie sufficientemente sofisticate per garantire un LLM completamente privo di bias, ma

sono comunque disponibili approcci che consentono di ridurli parzialmente.

5.2 Analisi dei Rischi Associati ai Bias per gli Utenti Finali

Sono stati descritti quali sono i pericoli da parte dell'utente (2.4), nell'utilizzare LLM attualmente biasati. Sono stati successivamente descritti quali sono le possibili strategie e comportamenti da applicare per proteggere l'utente (**Sezione 2.4**), definiti anche nella tabella 2.4

In letteratura sono stati definiti poi quali sono i comportamenti che che si dovrebbero applicare per proteggere l'utente (**Sezione 7.2.1**):

5.2.1 Strategie di Mitigazione Centrate sull'Utente

L'analisi precedente ha evidenziato i rischi cognitivi e comportamentali per gli utenti nell'interazione con gli LLM. Questa sezione propone strategie proattive per trasformare l'utente da soggetto passivo in un interlocutore critico, riducendone la vulnerabilità. L'approccio è integrato e si articola su tre pilastri principali: **alfabetizzazione algoritmica**, **design responsabile delle interfacce** e **responsabilità condivisa** tra utenti, sviluppatori e istituzioni.

Tabella 5.2: Strategie di mitigazione centrate sull'utente

Strategia	Descrizione e Implementazione
Alfabetizzazione Algoritmica	Educazione su funzionamento e limiti degli LLM (es. allucinazioni, bias nei dati). Sviluppo di consapevolezza critica applicata attraverso domande guida per valutare le risposte [95, 72].

Strategia	Descrizione e Implementazione
Design di Interfacce Critiche	Implementazione di *nudge* e *disclaimer* contestuali che ricordino la natura generativa del modello. Introduzione di indicatori di confidenza e promemoria per la verifica delle fonti per interrompere l'accettazione acritica [68, 70].
Pattern Interattivi Anti-bias	Strutturazione di interazioni che promuovano il pensiero critico, come modalità "analisi critica" in cui il modello solleva controargomenti, o *template* per esplorare pro e contro.
Adattamento al Contesto	In ambito **educativo**: integrazione di moduli sul pensiero critico e uso degli LLM come esercizio di analisi delle fonti. In contesti **professionali**: protocolli rigorosi con checklist di verifica e revisione tra pari [69]. Per utenti **personali**: strumenti semplificati di *fact-checking* e comunità online per verifica collaborativa.
Valutazione e Limiti	Necessità di valutazione rigorosa con metriche comportamentali e cognitive. Attenzione alla "warning fatigue" e all'esclusione di utenti con minore alfabetizzazione digitale. La responsabilità è condivisa: sviluppatori e regolatori devono ridurre i bias a monte [67, 71].

Le strategie sopra illustrate, pur valide, presentano un limite fondamentale: non sono soluzioni puramente tecniche, ma si affidano a una **maggior consapevolezza e**

azione proattiva da parte dell'utente. Come discusso nella Sezione 2.5.3, l'obiettivo prioritario degli sviluppatori e degli annotatori stessi non è sempre la creazione di un modello totalmente privo di bias, il che lascia all'utente finale un ruolo cruciale, ma anche oneroso, nella mitigazione dei rischi residui.

5.3 Discussione dei Risultati del Questionario

I dati raccolti dal questionario forniscono uno spaccato significativo delle percezioni e dei comportamenti di un campione prevalentemente giovane, studentesco e tecnologicamente familiare verso gli LLM. L'analisi integrata dei risultati quantitativi e qualitativi permette di delineare alcune tendenze chiave e potenziali aree critiche.

5.3.1 Un Profilo di Utente Consapevole ma Ancora Vulnerabile

Il campione, composto in maggioranza da giovani adulti (18–24 anni) con un background prevalentemente STEM, rappresenta una popolazione con probabile alta alfabetizzazione digitale. Ciò si riflette in un utilizzo frequente e pragmatico degli LLM per attività strumentali e produttive, come la scrittura e la risoluzione di problemi tecnici. Tuttavia, la stessa familiarità potrebbe alimentare una **fiducia operativa** che non si traduce automaticamente in una **consapevolezza critica** strutturata.

5.3.2 Il Paradosso dell'Uso Critico: Evitare vs. Affrontare i Bias

Emergono due tendenze apparentemente contraddittorie. Da un lato, gli utenti mostrano una significativa **riluttanza** a utilizzare gli LLM per scopi che coinvolgono direttamente le proprie opinioni, emozioni o giudizi di valore (es. questioni controverse, supporto emotivo, sostituzione di esperti). Questo suggerisce un'intuizione spontanea dei rischi associati a una delega eccessiva in ambiti sensibili.

Dall'altro lato, permangono comportamenti rischiosi. La metà degli intervistati (50.5%) ammette di accettare "a volte" risposte solo perché coerenti con le proprie aspettative, evidenziando la presenza del **bias di conferma** anche nell'interazione con l'IA. Inoltre, benché oltre la metà dichiari di verificare le informazioni, un terzo (33%)

lo fa "raramente", lasciando spazio a una potenziale diffusione acritica di contenuti errati o fuorvianti.

5.3.3 Il Riconoscimento dei Bias: Tra Percezione e Esperienza Diretta

Il dato sulla percezione degli stereotipi è emblematico: mentre il 41.2% li nota "qualche volta", una percentuale non trascurabile (30.9%) li rileva "raramente". Questo scarto potrebbe indicare una **sottostima** della pervasività dei bias, specialmente di quelli più sottili o culturalmente radicati. Le risposte aperte, tuttavia, rivelano che quando gli utenti incontrano errori fattuali palesi (specie in ambiti che conoscono bene, come lo studio o il coding), attivano prontamente meccanismi di correzione. La sfida risiede quindi nell'estendere questa attenzione critica anche a bias meno evidenti ma più insidiosi.

5.3.4 Dalle Preoccupazioni Qualitative all'Ecologia della Responsabilità

Le risposte aperte tracciano un quadro articolato di preoccupazioni che vanno ben oltre l'accuratezza fattuale. La paura della **dipendenza cognitiva**, della perdita di pensiero critico e della sostituzione impropria di professionisti umani (medici, psicologi) indica che gli utenti percepiscono i rischi sistemici dell'integrazione degli LLM nella società. Allo stesso tempo, l'entusiasmo per la facilità d'uso nell'apprendimento segnala il potenziale positivo di questi strumenti.

Questo dualismo enfatizza la necessità di un'**ecologia della responsabilità condivisa**, come anticipato nella Sezione 7.2.1. Gli utenti dimostrano di avere un'embrionale consapevolezza dei rischi, ma le loro strategie di mitigazione sono spesso reattive (correggere l'errore dopo) e dipendenti dalla loro expertise preesistente. Il compito di ricercatori, progettisti e policy maker è quello di costruire **scaffolding** educativi e tecnici che supportino un'interazione più consapevole e resiliente per tutti gli utenti, indipendentemente dal loro livello di competenza o dal contesto d'uso.

5.3.5 Limiti del Campione e Direzioni Future

È doveroso notare che il campione, sebbene informativo, non è rappresentativo della popolazione generale. La sua giovane età, l'alto livello di istruzione e la familiarità con le STEM potrebbero sovrastimare i livelli di consapevolezza critica e di alfabetizzazione algoritmica. Future ricerche dovrebbero coinvolgere un campione più eterogeneo per esplorare come queste dinamiche variano tra diversi gruppi demografici e professionali.

In conclusione, i risultati del questionario confermano che la mitigazione efficace dei bias non può essere un compito esclusivamente tecnico affidato agli algoritmi. Richiede un **coinvolgimento attivo e informato dell'utente**, supportato da un ecosistema di strumenti, educazione e governance progettato proprio per coltivare e sostenere tale coinvolgimento.

CAPITOLO 6

Conclusioni

Questo lavoro di tesi ha affrontato il problema dei bias nei LLM attraverso un'analisi duplice: una revisione strutturata dello stato dell'arte e un'indagine empirica sulle percezioni degli utenti. La ricerca ha raggiunto i suoi obiettivi principali, portando ai seguenti risultati chiave.

In primo luogo, è stata proposta e sviluppata una **tassonomia integrata** dei bias e delle strategie di mitigazione, organizzata secondo le fasi della pipeline di sviluppo. A differenza dei framework esistenti [4, 5], questa classificazione incorpora esplicitamente i **bias cognitivi e relazionali** che emergono nell'interazione tra utente e macchina, riconoscendo l'utente finale come anello cruciale—e vulnerabile—della catena.

In secondo luogo, l'analisi critica delle strategie di mitigazione (Pre-processing, In-training, Intra-processing, Post-processing e Prompt Engineering) ha dimostrato che, nello stato attuale, **nessun approccio è in grado di garantire un LLM totalmente privo di bias**. Ogni tecnica presenta limiti intrinseci, che vanno dal costo computazionale e dalla dimenticanza catastrofica alla dipendenza da definizioni semplificate di equità. Ciò conferma l'ipotesi centrale del lavoro: la ricerca di un modello "perfetto" è illusoria; l'obiettivo pratico deve essere la **gestione trasparente e la riduzione sistematica** dei bias.

In terzo luogo, lo studio qualitativo condotto su un campione di utenti prevalentemente giovani e tecnologicamente alfabetizzati ha rivelato un **paradosso comportamentale**. Se da un lato gli utenti evitano intuitivamente di usare gli LLM per decisioni critiche (mediche, etiche), dall'altro mostrano una significativa tendenza all'accettazione acritica delle risposte che confermano le loro aspettative (bias di conferma) e una verifica sporadica delle fonti. Questo evidenzia un **divario pericoloso** tra una consapevolezza teorica dei rischi e le pratiche d'uso quotidiane.

6.1 Limiti e Sviluppi Futuri

Il presente studio non è esente da limiti. La tassonomia proposta, sebbene sistematica, rimane un'astrazione concettuale che richiederebbe una validazione empirica più ampia. Il campione del questionario, sebbene informativo, non è rappresentativo della popolazione generale, essendo composto principalmente da giovani adulti con background STEM.

Queste limitazioni delineano chiare direzioni per la ricerca futura:

1. **Validazione empirica della tassonomia**: Sottoporre il framework proposto a valutazione e raffinamento da parte di esperti del settore.

2. **Studi longitudinali e su campioni diversificati**: Investigare come le percezioni e i comportamenti di rischio variano tra diversi gruppi demografici, culturali e professionali.

3. **Progettazione e testing di "scaffolding" critici**: Sviluppare e valutare l'efficacia di strumenti concreti (es. interfacce con *nudge*, protocolli di verifica) progettati per potenziare il pensiero critico dell'utente.

4. **Ricerca su metriche di "fairness" contestuali**: Spostare il focus da definizioni astratte di equità verso metriche pratiche calate in specifici domini applicativi (es. healthcare, giurisprudenza, educazione).

6.2 Impatto del Lavoro

Il contributo di questa tesi è duplice. Da un lato, fornisce a ricercatori e professionisti una **mappa concettuale aggiornata e critica** per orientarsi nel complesso panorama dei bias e delle contromisure, evidenziando i trade-off e le illusioni di ciascun approccio. Dall'altro, richiama l'attenzione sul **fattore umano**, spesso trascurato nel dibattito tecnico, argomentando che la mitigazione più efficace risiede in un'ecologia di **responsabilità condivisa**. Un LLM più equo non nasce solo da algoritmi migliori, ma da un ecosistema in cui sviluppatori, regolatori e utenti informati collaborano per gestirne i limiti inevitabili.

In conclusione, questa ricerca conferma che il cammino verso LLM equi e affidabili è ancora lungo. Tuttavia, chiarendo i limiti delle soluzioni tecniche pure e portando in primo piano la necessità di alfabetizzazione, design responsabile e governance, fornisce un fondamento per proseguire in modo più consapevole e pragmatico.

CAPITOLO 7

Discussione

In questo capitolo discutiamo dei risultati ottenuti e identifichiamo se gli obiettivi prefissati (Sezione 3.1) siano stati raggiunti o meno. Analizziamo i dati e risutati ottenuti, fornendo interpretazioni, implicazioni e successivamente nel capitolo delle conclusioni andiamo ad analizzare i limiti delle ricerche effettuate.

7.1 Analisi della Tassonomia Descritta

È stata prodotta una tassonomia che individua i bias negli LLM, schematizzandoli secondo l'ordine della pipeline di sviluppo (**Sezione 2.3**). Un lavoro analogo è stato svolto per le strategie di mitigazione, seguendo la medesima logica sequenziale.

L'analisi ha dimostrato come tutte le strategie di mitigazione esaminate non riescano a offrire una soluzione definitiva. Ciascuna presenta problematiche specifiche e limiti considerevoli che, nello stato dell'arte, rimangono ancora oggetto di discussione.

Tabella 7.1: Fasi di mitigazione del bias e relativi limiti principali

Fase	Limiti Critici
Pre-processing	Inefficacia delle tecniche di *data augmentation* basate su liste imperfette. Appiattimento identitario dei gruppi sociali. Introduzione di nuovi bias nel filtraggio automatico.
In-training	Costo computazionale elevato e necessità di accesso al modello. Rischio di *dimenticanza catastrofica* durante il *fine-tuning*. Definizioni semplificate di *fairness* nelle *loss function*. Scarsa validazione empirica comparativa.
Intra-processing	Squilibrio tra mitigazione del bias e diversità dell'output. Dipendenza da classificatori a loro volta *biased*. Vulnerabilità alla manipolazione per generare bias intenzionale.
Post-processing	Soggettività nella scelta degli output da correggere. Cancellazione di contesto importante nella riscrittura. Limitazione dai dati di addestramento paralleli disponibili.
Prompt Engineering	Instabilità ed efficacia dipendente dalla formulazione specifica. Azione superficiale che non corregge bias strutturali. Vulnerabilità all'elusione delle istruzioni. Responsabilità di mitigazione trasferita all'utente.

In letteratura sono presenti diverse ricerche focalizzate sulla descrizione e l'analisi dei bias riconosciuti nello sviluppo degli LLM e sulle criticità delle strategie di mitigazione (vedi 7.1); tali criticità interessano tutte le strategie esaminate. L'ipotesi centrale di questo studio è la seguente: nello stato attuale, non esistono strategie sufficientemente sofisticate per garantire un LLM completamente privo di bias, ma

sono comunque disponibili approcci che consentono di ridurli parzialmente.

7.2 Analisi dei Rischi Associati ai Bias per gli Utenti Finali

Sono stati descritti quali sono i pericoli da parte dell'utente (2.4), nell'utilizzare LLM attualmente biasati. Sono stati successivamente descritti quali sono le possibili strategie e comportamenti da applicare per proteggere l'utente (**Sezione 2.4**), definiti anche nella tabella 2.4

In letteratura sono stati definiti poi quali sono i comportamenti che che si dovrebbero applicare per proteggere l'utente (**Sezione 7.2.1**):

7.2.1 Strategie di Mitigazione Centrate sull'Utente

L'analisi precedente ha evidenziato i rischi cognitivi e comportamentali per gli utenti nell'interazione con gli LLM. Questa sezione propone strategie proattive per trasformare l'utente da soggetto passivo in un interlocutore critico, riducendone la vulnerabilità. L'approccio è integrato e si articola su tre pilastri principali: **alfabetizzazione algoritmica**, **design responsabile delle interfacce** e **responsabilità condivisa** tra utenti, sviluppatori e istituzioni.

Tabella 7.2: Strategie di mitigazione centrate sull'utente

Strategia	Descrizione e Implementazione
Alfabetizzazione Algoritmica	Educazione su funzionamento e limiti degli LLM (es. allucinazioni, bias nei dati). Sviluppo di consapevolezza critica applicata attraverso domande guida per valutare le risposte [95, 72].

Strategia	Descrizione e Implementazione
Design di Interfacce Critiche	Implementazione di *nudge* e *disclaimer* contestuali che ricordino la natura generativa del modello. Introduzione di indicatori di confidenza e promemoria per la verifica delle fonti per interrompere l'accettazione acritica [68, 70].
Pattern Interattivi Anti-bias	Strutturazione di interazioni che promuovano il pensiero critico, come modalità "analisi critica" in cui il modello solleva controargomenti, o *template* per esplorare pro e contro.
Adattamento al Contesto	In ambito **educativo**: integrazione di moduli sul pensiero critico e uso degli LLM come esercizio di analisi delle fonti. In contesti **professionali**: protocolli rigorosi con checklist di verifica e revisione tra pari [69]. Per utenti **personali**: strumenti semplificati di *fact-checking* e comunità online per verifica collaborativa.
Valutazione e Limiti	Necessità di valutazione rigorosa con metriche comportamentali e cognitive. Attenzione alla "warning fatigue" e all'esclusione di utenti con minore alfabetizzazione digitale. La responsabilità è condivisa: sviluppatori e regolatori devono ridurre i bias a monte [67, 71].

Le strategie sopra illustrate, pur valide, presentano un limite fondamentale: non sono soluzioni puramente tecniche, ma si affidano a una **maggior consapevolezza e**

azione proattiva da parte dell'utente. Come discusso nella Sezione 2.5.3, l'obiettivo prioritario degli sviluppatori e degli annotatori stessi non è sempre la creazione di un modello totalmente privo di bias, il che lascia all'utente finale un ruolo cruciale, ma anche oneroso, nella mitigazione dei rischi residui.

7.3 Discussione dei Risultati del Questionario

I dati raccolti dal questionario forniscono uno spaccato significativo delle percezioni e dei comportamenti di un campione prevalentemente giovane, studentesco e tecnologicamente familiare verso gli LLM. L'analisi integrata dei risultati quantitativi e qualitativi permette di delineare alcune tendenze chiave e potenziali aree critiche.

7.3.1 Un Profilo di Utente Consapevole ma Ancora Vulnerabile

Il campione, composto in maggioranza da giovani adulti (18–24 anni) con un background prevalentemente STEM, rappresenta una popolazione con probabile alta alfabetizzazione digitale. Ciò si riflette in un utilizzo frequente e pragmatico degli LLM per attività strumentali e produttive, come la scrittura e la risoluzione di problemi tecnici. Tuttavia, la stessa familiarità potrebbe alimentare una **fiducia operativa** che non si traduce automaticamente in una **consapevolezza critica** strutturata.

7.3.2 Il Paradosso dell'Uso Critico: Evitare vs. Affrontare i Bias

Emergono due tendenze apparentemente contraddittorie. Da un lato, gli utenti mostrano una significativa **riluttanza** a utilizzare gli LLM per scopi che coinvolgono direttamente le proprie opinioni, emozioni o giudizi di valore (es. questioni controverse, supporto emotivo, sostituzione di esperti). Questo suggerisce un'intuizione spontanea dei rischi associati a una delega eccessiva in ambiti sensibili.

Dall'altro lato, permangono comportamenti rischiosi. La metà degli intervistati (50.5%) ammette di accettare "a volte" risposte solo perché coerenti con le proprie aspettative, evidenziando la presenza del **bias di conferma** anche nell'interazione con l'IA. Inoltre, benché oltre la metà dichiari di verificare le informazioni, un terzo (33%)

lo fa "raramente", lasciando spazio a una potenziale diffusione acritica di contenuti errati o fuorvianti.

7.3.3 Il Riconoscimento dei Bias: Tra Percezione e Esperienza Diretta

Il dato sulla percezione degli stereotipi è emblematico: mentre il 41.2% li nota "qualche volta", una percentuale non trascurabile (30.9%) li rileva "raramente". Questo scarto potrebbe indicare una **sottostima** della pervasività dei bias, specialmente di quelli più sottili o culturalmente radicati. Le risposte aperte, tuttavia, rivelano che quando gli utenti incontrano errori fattuali palesi (specie in ambiti che conoscono bene, come lo studio o il coding), attivano prontamente meccanismi di correzione. La sfida risiede quindi nell'estendere questa attenzione critica anche a bias meno evidenti ma più insidiosi.

7.3.4 Dalle Preoccupazioni Qualitative all'Ecologia della Responsabilità

Le risposte aperte tracciano un quadro articolato di preoccupazioni che vanno ben oltre l'accuratezza fattuale. La paura della **dipendenza cognitiva**, della perdita di pensiero critico e della sostituzione impropria di professionisti umani (medici, psicologi) indica che gli utenti percepiscono i rischi sistemici dell'integrazione degli LLM nella società. Allo stesso tempo, l'entusiasmo per la facilità d'uso nell'apprendimento segnala il potenziale positivo di questi strumenti.

Questo dualismo enfatizza la necessità di un'**ecologia della responsabilità condivisa**, come anticipato nella Sezione 7.2.1. Gli utenti dimostrano di avere un'embrionale consapevolezza dei rischi, ma le loro strategie di mitigazione sono spesso reattive (correggere l'errore dopo) e dipendenti dalla loro expertise preesistente. Il compito di ricercatori, progettisti e policy maker è quello di costruire **scaffolding** educativi e tecnici che supportino un'interazione più consapevole e resiliente per tutti gli utenti, indipendentemente dal loro livello di competenza o dal contesto d'uso.

7.3.5 Limiti del Campione e Direzioni Future

È doveroso notare che il campione, sebbene informativo, non è rappresentativo della popolazione generale. La sua giovane età, l'alto livello di istruzione e la familiarità con le STEM potrebbero sovrastimare i livelli di consapevolezza critica e di alfabetizzazione algoritmica. Future ricerche dovrebbero coinvolgere un campione più eterogeneo per esplorare come queste dinamiche variano tra diversi gruppi demografici e professionali.

In conclusione, i risultati del questionario confermano che la mitigazione efficace dei bias non può essere un compito esclusivamente tecnico affidato agli algoritmi. Richiede un **coinvolgimento attivo e informato dell'utente**, supportato da un ecosistema di strumenti, educazione e governance progettato proprio per coltivare e sostenere tale coinvolgimento.

Bibliografia

[1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," *Advances in Neural Information Processing Systems*, vol. 30, 2017. (Citato alle pagine 1, 13, 14 e 40)

[2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," *arXiv preprint arXiv:1810.04805*, 2018. [Online]. Available: https://arxiv.org/abs/1810.04805 (Citato alle pagine 1, 9, 13 e 16)

[3] A. Radford, K. Narasimhan, T. Salimans, and I. Sutskever, "Improving language understanding by generative pre-training," OpenAI, Tech. Rep., 2018. [Online]. Available: https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf (Citato alle pagine 1, 9, 10 e 13)

[4] I. O. Gallegos, R. A. Rossi, J. Barrow, M. M. Tanjim, S. Kim, F. Dernoncourt, T. Yu, R. Zhang, and N. Ahmed, "Bias and fairness in large language models: A survey," *Computational Linguistics*, vol. 50, pp. 1097–1179, 2023. (Citato alle pagine 1, 13, 30, 31, 32, 33, 34, 38, 40 e 55)

[5] E. Ferrara, "Should chatgpt be biased? challenges and risks of bias in large language models," *First Monday*, vol. 28, 2023. (Citato alle pagine 1, 5, 8, 10, 11, 15, 36, 40 e 55)

[6] R. Navigli, S. Conia, and B. Ross, "Biases in large language models: Origins, inventory, and discussion," *ACM Journal of Data and Information Quality*, vol. 15, pp. 1 – 21, 2023. (Citato alle pagine 1, 10, 11, 12 e 40)

[7] Y. Guo, M. Guo, J. Su, Z. Yang, M. Zhu, H. Li, M. Qiu, and S. S. Liu, "Bias in large language models: Origin, evaluation, and mitigation," 11 2024. [Online]. Available: http://arxiv.org/abs/2411.10915 (Citato alle pagine 1, 4, 8, 22, 29, 31 e 40)

[8] A. Tversky and D. Kahneman, "Judgment under uncertainty: Heuristics and biases," *Science*, vol. 185, no. 4157, pp. 1124–1131, 1974. (Citato alle pagine 4, 5 e 6)

[9] D. Kahneman, *Thinking, Fast and Slow*. Farrar, Straus and Giroux, 2011. (Citato alle pagine 4, 5 e 6)

[10] E. M. Bender, T. Gebru, A. McMillan-Major, and S. Shmitchell, "On the dangers of stochastic parrots: Can language models be too big?" *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency*, pp. 610–623, 2021. (Citato alle pagine 4, 6, 7, 8, 13, 14 e 36)

[11] T. Bolukbasi, K.-W. Chang, J. Zou, V. Saligrama, and A. Kalai, "Man is to computer programmer as woman is to homemaker? debiasing word embeddings," *Advances in Neural Information Processing Systems*, vol. 29, 2016. (Citato alle pagine 4, 6 e 8)

[12] H. A. Simon, *A behavioral model of rational choice*. Quarterly Journal of Economics, 1955. (Citato a pagina 5)

[13] F. Flore, "Bias cognitivi: come la nostra mente ci inganna," 5 2018. [Online]. Available: https://milano-sfu.it/bias-cognitivi/ (Citato a pagina 6)

[14] A. Caliskan, J. J. Bryson, and A. Narayanan, "Semantics derived automatically from language corpora contain human-like biases," *Science*, vol. 356, no. 6334, pp. 183–186, 2017. (Citato a pagina 7)

[15] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman, and A. Galstyan, "A survey on bias and fairness in machine learning," *ACM Computing Surveys*, vol. 54, no. 6, pp. 1–35, 2021. (Citato alle pagine 7 e 15)

[16] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell *et al.*, "Language models are few-shot learners," *Advances in Neural Information Processing Systems*, vol. 33, pp. 1877–1901, 2020. [Online]. Available: https://arxiv.org/abs/2005.14165 (Citato alle pagine 7, 9, 10, 31 e 35)

[17] A. Chowdhery, S. Narang, J. Devlin, M. Bosma, G. Mishra, A. Roberts, P. Barham, H. W. Chung, C. Sutton, S. Gehrmann *et al.*, "Palm: Scaling language modeling with pathways," *Journal of Machine Learning Research*, vol. 24, no. 240, pp. 1–113, 2023. [Online]. Available: https://arxiv.org/abs/2204.02311 (Citato alle pagine 7 e 9)

[18] D. AI, "Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model," *arXiv preprint arXiv:2405.04434*, 2024. [Online]. Available: https://arxiv.org/abs/2405.04434 (Citato alle pagine 7 e 25)

[19] M. AI, "Announcing mistral 7b," https://mistral.ai/news/announcing-mistral-7b/, 2023, accessed: 2024-03-20. (Citato a pagina 7)

[20] OpenAI, "Gpt-4 technical report," Tech. Rep., 2023, accessed: 2024-03-20. [Online]. Available: https://cdn.openai.com/papers/gpt-4.pdf (Citato a pagina 7)

[21] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar *et al.*, "Llama: Open and efficient foundation language models," *arXiv preprint arXiv:2302.13971*, 2023. [Online]. Available: https://arxiv.org/abs/2302.13971 (Citato alle pagine 7 e 9)

[22] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale *et al.*, "Llama 2: Open foundation and fine-tuned chat models," *arXiv preprint arXiv:2307.09288*, 2023. [Online]. Available: https://arxiv.org/abs/2307.09288 (Citato a pagina 7)

[23] S. Wolfram, "What is chatgpt doing and why does it work?" *Wolfram Media, Inc.*, 2023. (Citato a pagina 7)

[24] P. Resnik, "Large language models are biased because they are large language models," 3 2025. [Online]. Available: http://arxiv.org/abs/2406.13138 (Citato alle pagine 8, 15 e 40)

[25] Z. Jiang, F. F. Xu, J. Araki, and G. Neubig, "How can we know what language models know?" *Transactions of the Association for Computational Linguistics*, vol. 8, pp. 423–438, 2020. (Citato a pagina 9)

[26] N. Carlini, F. Tramer, E. Wallace, M. Jagielski, A. Herbert-Voss, K. Lee, A. Roberts, T. B. Brown, D. Song, U. Erlingsson *et al.*, "Extracting training data from large language models," in *30th USENIX Security Symposium (USENIX Security 21)*, 2021, pp. 2633–2650. [Online]. Available: https://www.usenix.org/conference/usenixsecurity21/presentation/carlini-extracting (Citato a pagina 9)

[27] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, "Exploring the limits of transfer learning with a unified text-to-text transformer," *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1–67, 2020. [Online]. Available: http://jmlr.org/papers/v21/20-074.html (Citato a pagina 9)

[28] OpenAI, "Gpt-4 technical report," 2023. [Online]. Available: https://arxiv.org/abs/2303.08774 (Citato a pagina 9)

[29] ——, "Gpt-4 system card," OpenAI, Tech. Rep., 2023. [Online]. Available: https://cdn.openai.com/papers/gpt-4-system-card.pdf (Citato a pagina 9)

[30] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, and I. Sutskever, "Language models are unsupervised multitask learners," *OpenAI blog*, vol. 1, no. 8, p. 9, 2019. [Online]. Available: https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf (Citato alle pagine 9, 10 e 13)

[31] J. W. Rae, S. Borgeaud, T. Cai, K. Millican, J. Hoffmann, F. Song, J. Aslanides, S. Henderson, R. Ring, S. Young *et al.*, "Scaling language models: Methods, analysis & insights from training gopher," *arXiv preprint arXiv:2112.11446*, 2021. [Online]. Available: https://arxiv.org/abs/2112.11446 (Citato a pagina 9)

[32] D. Chen, Y. Huang, Z. Ma, H. Chen, X. Pan, C. Ge, D. Gao, Y. Xie, Z. Liu, J. Gao *et al.*, "Data-juicer: A one-stop data processing system for large language models," in *Companion of the 2024 International Conference on Management of Data*, 2024, pp. 120–134. (Citato a pagina 9)

[33] N. Sachdeva, B. Coleman, W.-C. Kang, J. Ni, L. Hong, E. H. Chi, J. Caverlee, J. McAuley, and D. Z. Cheng, "How to train data-efficient llms," 2 2024. [Online]. Available: http://arxiv.org/abs/2402.09668 (Citato a pagina 10)

[34] V. Iyer, B. Malik, P. Stepachev, P. Chen, B. Haddow, and A. Birch, "Quality or quantity? on data scale and diversity in adapting large language models for low-resource translation," 10 2024. [Online]. Available: http://arxiv.org/abs/2408.12780 (Citato a pagina 10)

[35] R. E. Nisbett and D. Cohen, *Culture of honor: The psychology of violence in the South*. Westview Press, 2001. (Citato a pagina 11)

[36] G. Hofstede, G. J. Hofstede, and M. Minkov, *Cultures and organizations: Software of the mind*. McGraw-Hill, 2010. (Citato a pagina 11)

[37] H. R. Markus and S. Kitayama, "Culture and the self: Implications for cognition, emotion, and motivation," *Psychological Review*, vol. 98, no. 2, pp. 224–253, 1991. (Citato a pagina 11)

[38] Z. Liu, "Cultural bias in large language models: A comprehensive analysis and mitigation strategies," *Journal of Transcultural Communication*, vol. 3, pp. 224–244, 5 2025. (Citato alle pagine 11 e 20)

[39] A. G. Greenwald, D. E. McGhee, and J. L. K. Schwartz, "Measuring individual differences in implicit cognition: The implicit association test," *Journal of Personality and Social Psychology*, vol. 74, no. 6, pp. 1464–1480, 1998. (Citato a pagina 11)

[40] L. A. Rudman and P. Glick, "Social justice and the gender gap: A review of the literature," *Journal of Social Issues*, vol. 60, no. 4, pp. 683–699, 2004. (Citato a pagina 11)

[41] A. H. Eagly, "Gender and social influence: A social psychological analysis," *American Psychologist*, vol. 39, no. 9, pp. 971–981, 1984. (Citato a pagina 11)

[42] P. Nemani, Y. D. Joel, P. Vijay, and F. F. Liza, "Gender bias in transformers: A comprehensive review of detection and mitigation strategies," *Natural Language Processing Journal*, vol. 6, p. 100047, 3 2024. (Citato a pagina 11)

[43] P. H. Ditto, B. S. Liu, C. J. Clark, S. P. Wojcik, E. E. Chen, R. H. Grady, and J. F. Zinger, "Motivated reasoning and political partisanship," *Political Psychology*, vol. 39, no. S1, pp. 127–143, 2018. (Citato a pagina 12)

[44] C. S. Taber and M. Lodge, "Motivated skepticism in the evaluation of political beliefs," *American Journal of Political Science*, vol. 50, no. 3, pp. 755–769, 2006. (Citato a pagina 12)

[45] Z. Kunda, "The case for motivated reasoning," *Psychological Bulletin*, vol. 108, no. 3, pp. 480–498, 1990. (Citato a pagina 12)

[46] T. Hagendorff, "On the inevitability of left-leaning political bias in aligned language models," University of Stuttgart, Tech. Rep., 2025. (Citato a pagina 12)

[47] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray *et al.*, "Training language models to follow instructions with human feedback," *Advances in Neural Information Processing Systems*, vol. 35, pp. 27 730–27 744, 2022. (Citato alle pagine 13 e 18)

[48] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," *arXiv preprint arXiv:1301.3781*, 2013. (Citato a pagina 13)

[49] K. Ethayarajh, "How contextual are contextualized word representations? comparing the geometry of bert, elmo, and gpt-2 embeddings," *arXiv preprint arXiv:1909.00512*, 2019. (Citato a pagina 13)

[50] S. L. Blodgett, S. Barocas, H. Daumé III, and H. Wallach, "Language (technology) is power: A critical survey of" bias" in nlp," *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pp. 5454–5476, 2020. (Citato a pagina 14)

[51] J. Zhao, T. Wang, M. Yatskar, V. Ordonez, and K.-W. Chang, "Men also like shopping: Reducing gender bias amplification using corpus-level constraints," *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pp. 2979–2989, 2017. (Citato a pagina 15)

[52] R. Bommasani, D. A. Hudson, E. Adeli, R. Altman, S. Arora *et al.*, "On the opportunities and risks of foundation models," *arXiv preprint arXiv:2108.07258*, 2021. (Citato a pagina 15)

[53] L. Weidinger, J. Mellor, M. Rauh, C. Griffin, J. Uesato *et al.*, "Ethical and social risks of harm from language models," *arXiv preprint arXiv:2112.04359*, 2021. (Citato a pagina 15)

[54] J. Dodge, M. Sap, A. Marasović, W. Agnew, D. Groeneveld, G. Ilharco, and M. Mitchell, "Documenting large webtext corpora: A case study on the colossal clean crawled corpus," *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pp. 1286–1305, 2021. (Citato a pagina 15)

[55] K. Singhal, S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung, N. Scales, A. Tanwani, H. Cole-Lewis, S. Pfohl *et al.*, "Large language models encode clinical knowledge," *Nature*, vol. 620, no. 7972, pp. 172–180, 2022. (Citato a pagina 17)

[56] J. Wei, M. Bosma, V. Y. Zhao, K. Guu, A. W. Views, Q. V. Le, and E. H. Chi, "Fine-tuned language models are zero-shot learners," *arXiv preprint arXiv:2109.01652*, 2021. (Citato alle pagine 17 e 23)

[57] A. Askell, Y. Bai, A. Chen, D. Drain, S. Fort, D. Ganguli, T. Henighan, A. Jones, N. Joseph, B. Mann *et al.*, "A general language assistant as a laboratory for alignment," *arXiv preprint arXiv:2112.00861*, 2021. (Citato a pagina 17)

[58] I. Gabriel, "The art of ai alignment: A survey of techniques and frameworks," *AI Ethics*, vol. 1, no. 3, pp. 231–248, 2020. (Citato a pagina 17)

[59] Y. Bai, A. Jones, K. Ndousse, A. Askell, A. Chen, N. DasSarma, D. Drain, S. Fort, D. Ganguli, T. Henighan *et al.*, "Training a helpful and harmless assistant with reinforcement learning from human feedback," *arXiv preprint arXiv:2204.05862*, 2022. (Citato alle pagine 18, 19, 21 e 23)

[60] S. Santurkar, E. Durmus, F. Ladhak, C. Lee, P. Liang, and T. Hashimoto, "Whose opinions do language models reflect?" *arXiv preprint arXiv:2303.17548*, 2023. (Citato alle pagine 19 e 21)

[61] C. Si, H. Lee, L. Zhang, Z. Liu, Z. Wang, M. Li, and N. Chen, "Multi-dimensional bias in conversational ai," *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, 2023. (Citato alle pagine 19 e 21)

[62] S. Casper, X. Davies, C. Shi, T. K. Gilbert, J. Scheurer, J. Rando, R. Freedman, T. Korbak, D. Lindner, P. Freire *et al.*, "Open problems and fundamental limitations of reinforcement learning from human feedback," *arXiv preprint arXiv:2307.15217*, 2023. (Citato alle pagine 19 e 21)

[63] M. Sharma, M. Tong, T. Korbak, D. Duvenaud, A. Askell, S. R. Bowman, N. Cheng, E. Durmus, Z. Hatfield-Dodds, S. R. Johnston *et al.*, "Towards understanding sycophancy in language models," *arXiv preprint arXiv:2310.13548*, 2023. (Citato alle pagine 19, 21 e 22)

[64] A. Wei, N. Haghtalab, and J. Steinhardt, "Jailbroken: How does llm safety training fail?" *Advances in Neural Information Processing Systems*, vol. 36, pp. 35 337–35 354, 2023. (Citato alle pagine 19 e 21)

[65] A. Liu, B. Feng, B. Xue, B. Wang, B. Wu, C. Lu, C. Zhao, C. Deng, C. Zhang, C. Ruan *et al.*, "Deepseek-v3 technical report," *arXiv preprint arXiv:2412.19437*, 2024. (Citato a pagina 23)

[66] I. D. Raji, E. M. Bender, A. Paullada, E. Denton, and A. Hanna, "Ai and the everything in the whole wide world benchmark," *arXiv preprint arXiv:2111.15366*, 2021. (Citato a pagina 23)

[67] J. T. Hancock and M. Naaman, "Ai-mediated communication: How the perception that profile text was written by ai affects trustworthiness," *Proceedings of the*

ACM on Human-Computer Interaction, vol. 4, no. CSCW, pp. 1–19, 2020. (Citato alle pagine 24, 38 e 61)

[68] J. B. Luguri and L. J. Strahilevitz, "Using algorithms to make ethical judgments: Malleability of algorithmic justice," *Behavioral Science & Policy*, vol. 7, no. 1, pp. 1–17, 2021. (Citato alle pagine 24, 37 e 61)

[69] J. M. Logg, J. A. Minson, and D. A. Moore, "Algorithm appreciation: People prefer algorithmic to human judgment," *Organizational Behavior and Human Decision Processes*, vol. 151, pp. 90–103, 2019. (Citato alle pagine 24, 25, 38 e 61)

[70] L. Nadarevic and R. Reber, "The (i)llusion of truth: How the availability of explanations influences judgments of truth for ai-generated statements," *Computers in Human Behavior*, vol. 113, p. 106503, 2020. (Citato alle pagine 24, 25, 37 e 61)

[71] M. Yeomans, "How algorithmic inferences can produce unjust outcomes: The case of algorithmic policing," *Behavioral Science & Policy*, vol. 7, no. 2, pp. 22–33, 2021. (Citato alle pagine 24, 25, 38 e 61)

[72] L. J. Skitka, B. E. Hanson, and D. C. Wisneski, "The psychology of technology-assisted decision making: Implications for ethics and policy," *Current Opinion in Psychology*, vol. 38, pp. 88–93, 2021. (Citato alle pagine 25, 37 e 60)

[73] A. Naseh, H. Chaudhari, J. Roh, M. Wu, A. Oprea, and A. Houmansadr, "R1dacted: Investigating local censorship in deepseek's r1 language model," *arXiv preprint arXiv:2505.12625*, 2025. (Citato a pagina 26)

[74] M. Rayila, "The pain of a nation: The invisibility of uyghurs in china proper," *The Equal Rights Review*, vol. 6, no. 1, pp. 44–57, 2011. (Citato a pagina 26)

[75] M. Clarke, "China and the uyghurs: the'palestinization'of xinjiang?" *Middle East Policy*, vol. 22, no. 3, 2015. (Citato a pagina 26)

[76] D. Zhao, "A brief history of the 1989 movement," in *The Power of Tiananmen: State-Society Relations and the 1989 Beijing Student Movement*. University of Chicago Press, 04 2001. [Online]. Available: https://doi.org/10.7208/chicago/9780226982625.003.0007 (Citato a pagina 27)

[77] C. J. Carolan, "The republic of taiwan: A legal-historical justification for a taiwanese declaration of independence," *NYUL Rev.*, vol. 75, p. 429, 2000. (Citato a pagina 28)

[78] H. Allam, D. Hua, L. Orozco, B. K. Gyamfi, D. Ahengua *et al.*, "Bias in ai: A comparative analysis of deepseek and chatgpt," *The Artificial Intelligence Business Review*, vol. 1, no. 1, 2025. (Citato a pagina 28)

[79] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong, Y. Du, C. Yang, Y. Chen, Z. Chen, J. Jiang, R. Ren, Y. Li, X. Tang, Z. Liu, P. Liu, J.-Y. Nie, and J.-R. Wen, "A survey of large language models," 3 2025. [Online]. Available: http://arxiv.org/abs/2303.18223 (Citato a pagina 31)

[80] S. Jin, Y. Wang, S. Liu, Y. Zhang, and W. Gu, "Optimizing dataset creation: A general purpose data filtering system for training large language models," 10 2024. [Online]. Available: https://www.authorea.com/users/840085/articles/1230466-optimizing-dataset-creation-a-general-purpose-data-filtering-system-for-training-commit=eecd40f9496f0bffa5f99096ecead5f2662d9f3c (Citato a pagina 31)

[81] J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska *et al.*, "Overcoming catastrophic forgetting in neural networks," *Proceedings of the national academy of sciences*, vol. 114, no. 13, pp. 3521–3526, 2017. (Citato a pagina 32)

[82] M. Gira, R. Zhang, and K. Lee, "Debiasing pre-trained language models via efficient fine-tuning," in *Proceedings of the second workshop on language technology for equality, diversity and inclusion*, 2022, pp. 59–69. (Citato a pagina 32)

[83] L. Ranaldi, E. S. Ruzzetti, D. Venditti, D. Onorati, and F. M. Zanzotto, "A trip towards fairness: Bias and de-biasing in large language models," in *Proceedings of the 13th Joint Conference on Lexical and Computational Semantics (* SEM 2024)*, 2024, pp. 372–384. (Citato a pagina 32)

[84] P. Joniak and A. Aizawa, "Gender biases and where to find them: Exploring gender bias in pre-trained transformer-based language models using movement

pruning," in *Proceedings of the 4th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, 2022, pp. 67–73. (Citato a pagina 32)

[85] V. Sanh, T. Wolf, and A. Rush, "Movement pruning: Adaptive sparsity by fine-tuning," *Advances in neural information processing systems*, vol. 33, pp. 20 378–20 389, 2020. (Citato a pagina 32)

[86] P. P. Liang, C. Wu, L.-P. Morency, and R. Salakhutdinov, "Towards understanding and mitigating social biases in language models," in *International conference on machine learning*. PMLR, 2021, pp. 6565–6576. (Citato a pagina 33)

[87] A. Liu, M. Sap, X. Lu, S. Swayamdipta, C. Bhagavatula, N. A. Smith, and Y. Choi, "Dexperts: Decoding-time controlled text generation with experts and anti-experts," *arXiv preprint arXiv:2105.03023*, 2021. (Citato a pagina 33)

[88] J. Chung, E. Kamar, and S. Amershi, "Increasing diversity while maintaining accuracy: Text data generation with large language models and human interventions," in *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2023, pp. 575–593. (Citato a pagina 33)

[89] E. Sheng, K.-W. Chang, P. Natarajan, and N. Peng, ""nice try, kiddo": Investigating ad hominems in dialogue responses," in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2021, pp. 750–767. (Citato a pagina 33)

[90] D. Saunders, R. Sallis, and B. Byrne, "First the worst: Finding better gender translations during beam search," in *Findings of the Association for Computational Linguistics: ACL 2022*, 2022, pp. 3814–3823. (Citato a pagina 33)

[91] J. Xu, D. Ju, M. Li, Y.-L. Boureau, J. Weston, and E. Dinan, "Recipes for safety in open-domain chatbots," *arXiv preprint arXiv:2010.07079*, 2020. (Citato a pagina 33)

[92] S. Gehman, S. Gururangan, M. Sap, Y. Choi, and N. A. Smith, "Realtoxicity-prompts: Evaluating neural toxic degeneration in language models," *arXiv preprint arXiv:2009.11462*, 2020. (Citato a pagina 33)

[93] S. Kumar, V. Balachandran, L. Njoo, A. Anastasopoulos, and Y. Tsvetkov, "Language generation models can cause harm: So what can we do about it? an actionable survey," in *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, 2023, pp. 3299–3321. (Citato a pagina 34)

[94] Y. Li, M. Du, R. Song, X. Wang, and Y. Wang, "A survey on fairness in large language models," *arXiv preprint arXiv:2308.10149*, 2023. (Citato alle pagine 35 e 36)

[95] E. Bender, T. Gebru *et al.*, "On the dangers of stochastic parrots," in *FAccT*, 2021. (Citato alle pagine 36 e 60)

Ringraziamenti

Vorrei innanzitutto ringraziare il Professor Palomba per avermi concesso il privilegio di lavorare presso il laboratorio SESA; grazie al suo contributo sono riuscito a realizzare questo lavoro.

Un ringraziamento speciale va alla mia famiglia, che ha sempre cercato di darmi il meglio. Nei momenti in cui le nostre idee non coincidevano, ha comunque fatto ogni sforzo per rispettare la mia volontà.

Ringrazio il gruppo di ragazzi con cui ho affrontato la triennale, i "Pastafariani": senza di loro la vita universitaria in questi anni sarebbe stata noiosa. Hanno contribuito moltissimo alla mia crescita, sia accademica che personale.

Desidero ringraziare inoltre gli amici che ci sono sempre stati, coloro che nei momenti di difficoltà mi hanno aiutato a rialzarmi.

Un grazie particolare va a Zaira, la rappresentazione dell'amore nella mia vita. Il suo contributo non può essere misurato: il suo supporto è stato fondamentale per questo studio, ma, in generale, la ringrazio ogni giorno.

Infine, ringrazio me stesso per essere riuscito ad affrontare tutte le sfide. Non sempre in modo perfetto, non sempre ci si è riusciti, ma alla fine eccomi qui.

Appendice Domande

Il seguente questionario è stato somministrato tramite Google Moduli all'interno dello studio intitolato "Quanto utilizzi criticamente gli Assistenti AI?". Il questionario aveva lo scopo di indagare le modalità di utilizzo, la percezione e il pensiero critico nei confronti dei Large Language Models (LLM) come ChatGPT, Gemini, Copilot e DeepSeek. Le domande erano anonime e includevano risposte chiuse, scale Likert e domande aperte facoltative.

Sezione 1 — Dati demografici

1. **Fascia d'età***
    - 14–17 anni
    - 18–24 anni
    - 25–30 anni
    - 31–35 anni
    - 36–40 anni
    - 41+
2. **Genere***
    - Uomo

- Donna
- Non-binario / Binario
- Preferisco non rispondere

3. **Livello di istruzione***

- Diploma superiore o inferiore
- Laurea triennale o simile
- Laurea magistrale o a ciclo unico
- Dottorato o Master

4. **Area di studio***

- STEM
- Scienze Umanistiche
- Scienze Sociali
- Medicina e Professioni Sanitarie
- Arte e Comunicazione
- Non studio
- Altro: _____

5. **Situazione lavorativa attuale***

- Studente (tempo pieno)
- Lavoratore (tempo pieno)
- Studente-lavoratore
- Disoccupato
- Inattivo (es. casalinga, pensione)
- Altro: _____

6. **Settore lavorativo (opzionale)**

- ICT & Sviluppo Software

- Ricerca & Sviluppo / Accademia
- Sanità e Medicina
- Consulenza
- Istruzione & Formazione
- Creative Industry & Media
- Legale & Amministrativo
- Vendite & Servizi
- Artigianato, Industria & Logistica
- Altro: _____

Sezione 2 — Utilizzo generale degli LLM

7. **Con quale frequenza utilizzi assistenti AI come ChatGPT, Gemini o DeepSeek?***

    - Almeno una volta al giorno
    - Qualche volta a settimana
    - Qualche volta al mese
    - Raramente
    - Mai

Sezione 3 — Modalità di utilizzo degli LLM

8. Cercare informazioni su argomenti che già conosco*
9. Esplorare nuovi argomenti di cui so poco*
10. Scrivere testi (email, relazioni, documenti)*
11. Correggere o migliorare testi che ho già scritto*
12. Generare idee creative o soluzioni innovative*

13. Trovare conferme alle mie opinioni personali*
14. Analizzare pro e contro di una decisione*
15. Risolvere problemi tecnici o di programmazione*
16. Preparare esami o studiare nuovi concetti*
17. Tradurre testi in altre lingue*
18. Chiedere opinioni su questioni controverse*
19. Verificare informazioni ottenute da altre fonti*
20. Ricevere supporto emotivo in situazioni di stress*
21. Consolidare la propria posizione durante un dibattito*
22. Accettare una risposta coerente solo perché coerente con le proprie aspettative*

Sezione 4 — Considerazioni sugli LLM

23. Quando ricevi una risposta che conferma la tua opinione, tendi a rafforzarla?*
24. Con quale frequenza noti stereotipi (di genere, culturali, ecc.) nelle risposte degli LLM?*
25. Quanto sei preoccupato dell'impatto degli assistenti AI sul futuro del tuo settore?*
26. In quali ambiti della tua vita gli assistenti AI hanno avuto maggiore impatto?*
27. Gli assistenti AI aiutano l'apprendimento scolastico/universitario?*
28. Quanto ritieni di comprendere come un LLM genera le proprie risposte?*
29. Quanto pensi che l'uso frequente degli LLM possa rafforzare inconsapevolmente le tue opinioni?*

Sezione 5 — Domande aperte (facoltative)

31. Racconta un episodio in cui un assistente AI ti ha fornito una risposta percepita come pregiudizievole, inesatta o fuorviante.

32. Descrivi una situazione in cui ritieni di aver usato (o visto usare) un assistente AI in modo improprio o rischioso.

33. C'è qualche aspetto dell'interazione con gli assistenti AI che ti lascia perplesso, preoccupato o entusiasta?

Nota: Le domande con asterisco (*) erano obbligatorie.

Risultati del Questionario

Questa appendice riporta una sintesi dei risultati del questionario *"Percezioni e Utilizzo degli Assistenti AI"*, somministrato online tramite Google Forms nel periodo 24 ottobre - 9 novembre 2025. Il questionario completo è disponibile in Appendice **??**.

*

Caratteristiche del campione

Il questionario è stato compilato da **97 partecipanti**. La Tabella 3 riassume le caratteristiche demografiche del campione.

Frequenza e modalità di utilizzo degli LLM

Frequenza di utilizzo

La Tabella 4 mostra la distribuzione della frequenza di utilizzo degli assistenti AI. Il 79.4% dei partecipanti li utilizza almeno una volta a settimana.

Scopi principali di utilizzo

La Tabella 5 presenta le medie delle risposte su scala Likert (1=Mai, 5=Sempre) per i principali scopi di utilizzo.

Tabella 3: Caratteristiche demografiche del campione (N=97)

Caratteristica	Categoria	Frequenza (%)
Fascia d'età	18–24 anni	92 (94.8%)
	25–30 anni	4 (4.1%)
	31–35 anni	1 (1.0%)
Genere	Uomo	48 (49.5%)
	Donna	46 (47.4%)
	Non-binario	2 (2.1%)
	Preferisco non rispondere	1 (1.0%)
Livello di istruzione	Diploma superiore	60 (61.9%)
	Laurea triennale	29 (29.9%)
	Laurea magistrale	6 (6.2%)
	Dottorato/Master	2 (2.1%)
Area di studio principale	STEM	52 (53.6%)
	Arte e Comunicazione	21 (21.6%)
	Scienze Umanistiche	13 (13.4%)
	Scienze Sociali	6 (6.2%)
	Medicina/Professioni Sanitarie	4 (4.1%)
	Altro/Non studio	1 (1.0%)

Percezioni sui bias e sugli stereotipi

Rilevazione di stereotipi

- **54.6%** dei partecipanti ha dichiarato di notare stereotipi nelle risposte degli LLM "qualche volta" o "spesso"
- Solo il **9.3%** ha risposto "mai"

Tabella 4: Frequenza di utilizzo degli assistenti AI (N=97)

Frequenza	Frequenza assoluta	Percentuale
Almeno una volta al giorno	36	37.1%
Qualche volta a settimana	41	42.3%
Qualche volta al mese	9	9.3%
Raramente	8	8.2%
Mai	3	3.1%

Tabella 5: Scopi principali di utilizzo degli LLM (scala 1-5)

Scopo di utilizzo	Media	Deviazione standard
Cercare informazioni su argomenti già conosciuti	4.2	0.8
Esplorare nuovi argomenti	3.8	0.9
Scrivere testi (email, documenti, relazioni)	3.5	1.1
Correggere o migliorare testi esistenti	3.2	1.2
Generare idee creative o soluzioni innovative	2.9	1.3
Trovare conferme alle opinioni personali	3.1	1.4
Analizzare i pro e contro di una decisione	3.4	1.0
Risolvere problemi tecnici o di programmazione	3.6	1.1
Preparare esami o studiare nuovi concetti	3.9	1.0

- I bias più frequentemente menzionati riguardano: genere (28.9%), culturali/nazionali (24.7%), professionali (19.6%)

Tendenza al rafforzamento delle opinioni

- **43.3%** ritiene che gli LLM possano "a volte" o "spesso" rafforzare le opinioni preesistenti
- **21.6%** si dichiara neutrale o incerto

- **35.1%** percepisce questo fenomeno come raro o inesistente

Analisi qualitativa delle risposte aperte

Le risposte aperte sono state analizzate mediante analisi tematica. I temi principali emersi sono sintetizzati di seguito.

Episodi di bias percepiti

I partecipanti hanno riportato 63 episodi specifici, classificabili in:

1. **Errori fattuali/allucinazioni** (42.9%): informazioni errate presentate con sicurezza
2. **Stereotipi culturali/politici** (28.6%): es. narrazioni filo-occidentali vs. filo-cinesi
3. **Bias di genere/professionali** (19.0%): associazioni stereotipate tra genere e professioni
4. **Mancanza di contesto** (9.5%): risposte generiche non adattate alla situazione specifica

Usi impropri osservati o messi in atto

- **Supporto psicologico/sanitario**: 24 menzioni di utilizzo per pareri medici o emotivi
- **Sostituzione del pensiero critico**: 18 menzioni di delega eccessiva in compiti accademici
- **Decisioni personali importanti**: 7 casi di utilizzo per scelte di vita significative
- **Generazione di contenuti senza verifica**: 14 casi di affidamento acritico

Tabella 6: Temi principali nelle considerazioni finali (N=73 risposte)

Tema	Frequenza	Percentuale
Preoccupazione per dipendenza cognitiva	31	42.5%
Timore di perdita di pensiero critico	28	38.4%
Entusiasmo per utilità pratica	22	30.1%
Preoccupazione per impatto lavorativo	19	26.0%
Curiosità verso evoluzione tecnologica	15	20.5%
Preoccupazione per bias/disinformazione	12	16.4%

Preoccupazioni ed entusiasmi emergenti

Limiti della rilevazione

I dati presentati devono essere interpretati considerando:

- **Campione non probabilistico** con sovrarappresentazione di giovani under-25 (94.8%) e studenti STEM (53.6%)
- **Natura auto-selettiva** della partecipazione
- **Strumento non standardizzato** (*ad hoc*)
- **Dati auto-riferiti** soggetti a bias di memoria e percezione

Nonostante questi limiti, i dati offrono spunti qualitativi preziosi per comprendere le dinamiche di interazione con gli LLM nella popolazione giovanile.